

RobertScience Data Analytics

Reporte Técnico de Proyecto

Consolidación y Preparación de Datos de Ventas

Proyecto Empresa Aliada - Entregable 1

Proyecto: Consolidación y Preparación de Datos de Ventas

Empresa: RobertsScience

Rol: Equipo Interno de Data Science

Herramientas: Python, Pandas, NumPy, Jupyter Notebook, Visual Studio Code

Versión Python: 3.11

1. Descripción General del Proyecto

Desarrollé este proyecto como parte del primer entregable del programa Empresa Aliada, con el objetivo de construir un flujo profesional de consolidación y preparación de datos comerciales.

Durante el desarrollo integré múltiples fuentes estructuradas de información, combinando una tabla principal de hechos de ventas con diferentes dimensiones comerciales. El resultado fue un dataset analítico consolidado, limpio y preparado para procesos posteriores de exploración, visualización y modelado.

El proyecto fue desarrollado siguiendo principios de Ingeniería de Datos y Ciencia de Datos, manteniendo separación entre datos originales y procesados, trazabilidad completa de transformaciones y validaciones estructurales durante cada etapa del flujo ETL.

2. Fuentes de Información Utilizadas

Para construir el dataset final utilicé cinco fuentes principales de información comercial:

- **FACT_SALES:** tabla principal de hechos con registros de ventas.
- **DIM_PRODUCT:** información descriptiva de productos.
- **DIM_CATEGORY:** clasificación de categorías comerciales.
- **DIM_SEGMENT:** información utilizada para segmentación.
- **DIM_CALENDAR:** dimensión temporal para análisis por periodos.

Nota sobre los datos originales:

Los archivos originales fueron utilizados exclusivamente como fuentes de entrada durante el proceso ETL. Estos archivos no fueron incluidos dentro del repositorio público debido a su tamaño, con el objetivo de mantener una estructura eficiente para control de versiones y facilitar la distribución del proyecto. La composición de las fuentes y el proceso aplicado se encuentran completamente documentados en el notebook técnico y en este reporte.

3. Arquitectura del Proyecto

014-proyecto-empresa-aliada-entrega1-consolidacion-datos-ventas/

|

|— robertscience_data/

|

|— raw/

| |— FACT_SALES

| |— DIM_PRODUCT

| |— DIM_CATEGORY

| |— DIM_SEGMENT

| |— DIM_CALENDAR

|

|— processed/

| |— sales_consolidated_final.csv

|

|— robertscience_notebooks/

```
| └─ rs_sales_data_consolidation.ipynb
```

```
|
```

```
| └─ robertscience_docs/
```

```
| └─ Reporte_Tecnico_Entrega1.pdf
```

```
|
```

```
└─ robertscience_requirements.txt
```

4. Proceso ETL Implementado

Carga de información

Desarrollé un proceso automatizado utilizando Python y Pandas para cargar las diferentes fuentes considerando su formato original. Se trabajó con archivos CSV y Excel utilizando las librerías correspondientes.

Exploración inicial

Realicé un análisis estructural para identificar:

- Número de registros.
- Número de columnas.
- Tipos de datos.
- Valores faltantes.
- Consistencia de llaves.

Limpieza y preparación

Apliqué procesos de limpieza enfocados en mejorar la calidad del dato:

- Tratamiento de valores faltantes.
- Normalización de variables.
- Corrección de inconsistencias.
- Preparación de llaves de integración.

Integración dimensional

La consolidación fue realizada mediante integraciones progresivas:

FACT_SALES

↓

DIM_PRODUCT

↓

DIM_CATEGORY

↓

DIM_SEGMENT

↓

DIM_CALENDAR

Cada unión fue validada mediante relaciones **many-to-one** para garantizar integridad referencial.

5. Validaciones Realizadas

- Validación de conservación del volumen original de ventas.
- Revisión de duplicados en dimensiones críticas.
- Normalización de llaves comerciales.
- Validación de registros sin correspondencia.
- Confirmación de integridad final del dataset.

6. Resultado Final

Dataset consolidado generado:

122,002 registros

23 columnas finales

Integridad referencial completa

Sin pérdida de registros

Sin duplicados críticos

Archivo generado:

```
sales_consolidated_final.csv
```

7. Tecnologías Utilizadas

- Python 3.11
- Pandas
- NumPy

- OpenPyXL
- Jupyter Notebook
- Visual Studio Code

8. Notebook Técnico

Todo el flujo de trabajo fue documentado dentro del notebook:

```
robertscience_notebooks/  
  
└─ rs_sales_data_consolidation.ipynb
```

El notebook contiene:

- Carga de fuentes.
- Análisis exploratorio.
- Limpieza.
- Transformaciones.
- Integraciones.
- Validaciones.
- Exportación final.

9. Conclusión

El proyecto permitió construir un pipeline completo de consolidación de datos comerciales siguiendo una metodología profesional de Ciencia de Datos.

El dataset final obtenido representa una base confiable, estructurada y preparada para siguientes etapas analíticas como exploración avanzada, construcción de indicadores, visualización mediante dashboards y desarrollo de modelos predictivos.

RobertsScience

Data Analytics & Engineering Solutions

<https://robertscience.online>