

FileEditSelectionViewGoRun<=>Tarea M21-CD – robertscience [Administrator]

Tarea_M21-CD_robertscience.ipynbTarea_M21-CD_robertscience.html3Tarea_M21-CD_robertscience.ipynb

notebooks>Tarea_M21-CD_robertscience.ipynb>M↓Tarea M21-CD – Análisis de Clasificación con K Vecinos Más Cercanos (KNN)>M↓Limitaciones y trabajo futuro

Generate+Code+MarkdownRun AllRestartClear All OutputsJupyter VariablesOutline...venv (Pyt

^

Tarea M21-CD – Análisis de Clasificación con K Vecinos Más Cercanos (KNN)

Profesión: Científico de Datos v2

Objetivo

El objetivo de esta práctica es desarrollar un modelo predictivo de clasificación utilizando el algoritmo de K Vecinos Más Cercanos (KNN), con el fin de identificar los factores que influyen en la decisión de los empleados de abandonar una empresa y evaluar el desempeño del modelo mediante métricas de clasificación.

Descripción general

Se trabaja con una base de datos de recursos humanos que contiene información sobre satisfacción laboral, desempeño, carga de trabajo, antigüedad, promociones, accidentes laborales y características contractuales. El análisis contempla la preparación de los datos, la recodificación de variables categóricas, la evaluación del modelo en diferentes clases y el entrenamiento de múltiples modelos KNN para distintos valores de k, seleccionando el modelo óptimo con base en su capacidad predictiva.

PROBLEMS3OUTPUTDEBUG CONSOLETERMINALPORTSJUPYTERQUERY RESULTS

msedge - notebooks+🗑️...

(.venv) PS C:\Users\ROBERTSCIENCE\Documents\Tarea_M21-CD – robertscience\notebooks> start Tarea_M21-CD_robertscience.html

FileEditSelectionViewGoRun<=>Tarea M21-CD – robertscience [Administrator]

Tarea_M21-CD_robertscience.ipynbTarea_M21-CD_robertscience.html3Tarea_M21-CD_robertscience.ipynb

notebooks > Tarea_M21-CD_robertscience.ipynb > M↓ Tarea M21-CD – Análisis de Clasificación con K Vecinos Más Cercanos (KNN) > M↓ Limitaciones y trabajo futuro

Generate + Code + Markdown | Run All Restart Clear All Outputs | Jupyter Variables Outlinevenv (Python 3.8.5)

accidentes laborales y características contractuales. El análisis contempla la preparación de los datos, la recodificación de variables categóricas, la evaluación del modelo para diferentes valores de k, la selección del modelo óptimo y el entrenamiento de múltiples modelos KNN para distintos valores de k, seleccionando el modelo óptimo con base en su capacidad predictiva.

Autor

RobertsScience – Consultoría en Ciencia de Datos

Metodología del análisis

En este proyecto se sigue una metodología de análisis de datos estructurada, orientada al desarrollo de un modelo predictivo de clasificación. El proceso inicia con la exploración y comprensión del conjunto de datos, seguida de la preparación de las variables mediante la recodificación de atributos categóricos y el escalado de variables numéricas.

Posteriormente, se entrena un modelo de K Vecinos Más Cercanos (KNN) evaluando distintos valores del parámetro k, con el objetivo de identificar la configuración que maximiza el desempeño predictivo. La evaluación del modelo se realiza a través de métricas de clasificación, una matriz de confusión y la curva ROC, permitiendo interpretar los resultados desde una perspectiva analítica y aplicada al contexto de recursos humanos.

Importación de librerías necesarias

PROBLEMS 3 OUTPUT DEBUG CONSOLE TERMINAL PORTS JUPYTER QUERY RESULTSmsedge - notebooks + v

(.venv) PS C:\Users\ROBERTSCIENCE\Documents\Tarea_M21-CD – robertscience\notebooks> start Tarea_M21-CD_robertscience.html

File

Edit

Selection

View

Go

Run

...

←

→

🔍

Tarea M21-CD – robertscience [Administrator]

🗨️

🔧

📄

🖨️

🔍

⌵

Tarea_M21-CD_robertscience.ipynb

✕

<> Tarea_M21-CD_robertscience.html 3

Tarea_M21-CD_robertscience.ipynb

✕

notebooks > Tarea_M21-CD_robertscience.ipynb > M↓ Tarea M21-CD – Análisis de Clasificación con K Vecinos Más Cercanos (KNN) > M↓ Limitaciones y trabajo futuro

🔧 Generate + Code + Markdown | ▶ Run All ↺ Restart ✕ Clear All Outputs | 📄 Jupyter Variables ☰ Outline ...

📁 .venv (Python 3.10.6)

Importación de librerías necesarias

En esta sección se importan las librerías fundamentales para el análisis de datos, visualización y construcción del modelo de clasificación. Estas herramientas permiten manipular los datos, generar gráficos y aplicar algoritmos de aprendizaje supervisado de manera eficiente.

```
# Importación de librerías necesarias
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

# Configuración visual
plt.style.use('default')
sns.set()

# Carga del dataset
df = pd.read_csv("../data/recursos_humanos.csv")

# Inspección inicial
df.head()
```

[3] ✓ 0.0s

PROBLEMS 3 OUTPUT DEBUG CONSOLE TERMINAL PORTS JUPYTER QUERY RESULTS

msedge - notebooks + 🗨️ 🗑️ ...

(.venv) PS C:\Users\ROBERTSCIENCE\Documents\Tarea_M21-CD – robertscience\notebooks> start Tarea_M21-CD_robertscience.html

FileEditSelectionViewGoRun

Tarea M21-CD – robertscience [Administrator]

msedge - notebooks

+

▾

🗑

⋮

Tarea_M21-CD_robertscience.ipynb

Tarea_M21-CD_robertscience.html 3

Tarea_M21-CD_robertscience.ipynb

notebooks > Tarea_M21-CD_robertscience.ipynb > M↓ Tarea M21-CD – Análisis de Clasificación con K Vecinos Más Cercanos (KNN) > M↓ Limitaciones y trabajo futuro

Generate

+ Code

+ Markdown

|

▶ Run All

↺ Restart

⌵ Clear All Outputs

|

📄 Jupyter Variables

☰ Outline

⋮

⌵

[3] ✓ 0.0s

...

	satisfaction_level	last_evaluation	number_project	average_monthly_hours	time_spend_company	Work_accident	left	promotion_last_5years	sales	salary
0	0.38	0.53	2	157	3	0	1	0	sales	low
1	0.80	0.86	5	262	6	0	1	0	sales	medium
2	0.11	0.88	7	272	4	0	1	0	sales	medium
3	0.72	0.87	5	223	5	0	1	0	sales	low
4	0.37	0.52	2	159	3	0	1	0	sales	low

Información general del conjunto de datos

Antes de proceder con la preparación y modelado de los datos, se realiza un análisis exploratorio inicial para comprender la estructura del conjunto de datos. Esta permite identificar el número de observaciones, el tipo de variables, la presencia de valores faltantes y las principales características estadísticas de los atributos numéricos.

Información general del dataset

df.info()

Estadísticos descriptivos de las variables numéricas

[4] ✓ 0.0s

PROBLEMS 3

OUTPUT

DEBUG CONSOLE

TERMINAL

PORTS

JUPYTER

QUERY RESULTS

(.venv) PS C:\Users\ROBERTSCIENCE\Documents\Tarea_M21-CD – robertscience\notebooks> start Tarea_M21-CD_robertscience.html

FileEditSelectionViewGoRun<Tarea M21-CD – robertscience [Administrator]

Tarea_M21-CD_robertscience.ipynbTarea_M21-CD_robertscience.html 3Tarea_M21-CD_robertscience.ipynb

notebooks > Tarea_M21-CD_robertscience.ipynb > Tarea M21-CD – Análisis de Clasificación con K Vecinos Más Cercanos (KNN) > Limitaciones y trabajo futuro

GenerateCodeMarkdownRun AllRestartClear All OutputsJupyter VariablesOutline.venv (Pyt

Estadísticos descriptivos de las variables numéricas

df.describe()

[4] ✓ 0.0s

<class 'pandas.DataFrame'>

RangeIndex: 14999 entries, 0 to 14998

Data columns (total 10 columns):

#	Column	Non-Null Count	Dtype
0	satisfaction_level	14999 non-null	float64
1	last_evaluation	14999 non-null	float64
2	number_project	14999 non-null	int64
3	average_monthly_hours	14999 non-null	int64
4	time_spend_company	14999 non-null	int64
5	Work_accident	14999 non-null	int64
6	left	14999 non-null	int64
7	promotion_last_5years	14999 non-null	int64
8	sales	14999 non-null	str
9	salary	14999 non-null	str

dtypes: float64(2), int64(6), str(2)

memory usage: 1.1 MB

	satisfaction_level	last_evaluation	number_project	average_monthly_hours	time_spend_company	Work_accident	left	promotion_last_5years
count	14999.000000	14999.000000	14999.000000	14999.000000	14999.000000	14999.000000	14999.000000	14999.000000

PROBLEMS 3OUTPUTDEBUG CONSOLETERMINALPORTSJUPYTERQUERY RESULTS

msedge - notebooks

(.venv) PS C:\Users\ROBERTSCIENCE\Documents\Tarea_M21-CD – robertscience\notebooks> start Tarea_M21-CD_robertscience.html

File

Edit

Selection

View

Go

Run

...

←

→

Tarea M21-CD – robertscience [Administrator]

🔍

🔗

📄

📁

⋮

Tarea_M21-CD_robertscience.ipynb

<> Tarea_M21-CD_robertscience.html 3

Tarea_M21-CD_robertscience.ipynb

notebooks > Tarea_M21-CD_robertscience.ipynb > M↓ Tarea M21-CD – Análisis de Clasificación con K Vecinos Más Cercanos (KNN) > M↓ Limitaciones y trabajo futuro

Generate

+ Code

+ Markdown

| Run All

| Restart

| Clear All Outputs

| Jupyter Variables

| Outline

| ...

.venv (Pyt

...

	satisfaction_level	last_evaluation	number_project	average_monthly_hours	time_spend_company	Work_accident	left	promotion_last_5years
count	14999.000000	14999.000000	14999.000000	14999.000000	14999.000000	14999.000000	14999.000000	14999.000000
mean	0.612834	0.716102	3.803054	201.050337	3.498233	0.144610	0.238083	0.021268
std	0.248631	0.171169	1.232592	49.943099	1.460136	0.351719	0.425924	0.144281
min	0.090000	0.360000	2.000000	96.000000	2.000000	0.000000	0.000000	0.000000
25%	0.440000	0.560000	3.000000	156.000000	3.000000	0.000000	0.000000	0.000000
50%	0.640000	0.720000	4.000000	200.000000	3.000000	0.000000	0.000000	0.000000
75%	0.820000	0.870000	5.000000	245.000000	4.000000	0.000000	0.000000	0.000000
max	1.000000	1.000000	7.000000	310.000000	10.000000	1.000000	1.000000	1.000000

Interpretación de la información del conjunto de datos

Se observa que el conjunto de datos no presenta valores nulos, lo que indica que no es necesario realizar procesos de imputación. Asimismo, el dataset combina variables numéricas continuas, variables discretas y variables categóricas, lo cual requerirá un tratamiento diferenciado durante la etapa de preparación de los datos.

Las variables numéricas presentan rangos y escalas distintas, por lo que será necesario aplicar un proceso de escalado antes de entrenar el modelo KNN, ya que este algoritmo se basa en el cálculo de distancias. La variable objetivo `left` es binaria, lo que confirma que el problema a resolver corresponde a un caso de clasificación supervisada.

PROBLEMS 3

OUTPUT

DEBUG CONSOLE

TERMINAL

PORTS

JUPYTER

QUERY RESULTS

msedge - notebooks

+

🔍

🗑️

...

(.venv) PS C:\Users\ROBERTSCIENCE\Documents\Tarea_M21-CD – robertscience\notebooks> start Tarea_M21-CD_robertscience.html

FileEditSelectionViewGoRun<Tarea M21-CD – robertscience [Administrator]

Tarea_M21-CD_robertscience.ipynbTarea_M21-CD_robertscience.html3Tarea_M21-CD_robertscience.ipynb

notebooks > Tarea_M21-CD_robertscience.ipynb > Tarea M21-CD – Análisis de Clasificación con K Vecinos Más Cercanos (KNN) > Limitaciones y trabajo futuro

GenerateCodeMarkdownRun AllRestartClear All OutputsJupyter VariablesOutline.venv (Python 3.8.5)

[6] ✓ 0.0s

... left
0 76.191746
1 23.808254
Name: proportion, dtype: float64

```
# Visualización del balance de clases  
sns.countplot(x='left', data=df)  
plt.title('Distribución de la variable objetivo (left)')  
plt.xlabel('Abandono de la empresa')  
plt.ylabel('Número de empleados')  
plt.show()
```

[7] ✓ 0.2s


...



PROBLEMS 3OUTPUTDEBUG CONSOLETERMINALPORTSJUPYTERQUERY RESULTS

msedge - notebooks + -

(.venv) PS C:\Users\ROBERTSCIENCE\Documents\Tarea_M21-CD – robertscience\notebooks> start Tarea_M21-CD_robertscience.html







File

Edit

Selection

View

Go

Run

...

←

→

🔍

Tarea M21-CD – robertscience [Administrator]

🗨️

🔧

📄

📄

📄

—

Tarea_M21-CD_robertscience.ipynb

✕

<> Tarea_M21-CD_robertscience.html 3

Tarea_M21-CD_robertscience.ipynb

✕

notebooks > Tarea_M21-CD_robertscience.ipynb > M↓ Tarea M21-CD – Análisis de Clasificación con K Vecinos Más Cercanos (KNN) > M↓ Preparación de los datos

Generate + Code + Markdown | Run All | Restart | Clear All Outputs | Jupyter Variables | Outline | ...

📁 .venv (Python 3.8.10)

Se utilizó el parámetro `drop_first=True` para evitar problemas de multicolinealidad y reducir la redundancia entre variables.

▶

```
# Separación de variables predictoras y variable objetivo
X = df_encoded.drop('left', axis=1)
y = df_encoded['left']

X.shape, y.shape
```

[9] ✓ 0.0s

... ((14999, 18), (14999,))

Separación de variables predictoras y variable objetivo

Se separó la variable objetivo `left` del resto del conjunto de datos. El conjunto `X` contiene todas las variables predictoras, mientras que `y` representa la variable respuesta binaria que indica si el empleado abandonó la empresa.

Esta separación es necesaria para entrenar y evaluar el modelo de clasificación de manera adecuada.

```
X_train.shape, X_test.shape
```

PROBLEMS 3

OUTPUT

DEBUG CONSOLE

TERMINAL

PORTS

JUPYTER

QUERY RESULTS

msedge - notebooks + 🗨️ 🗑️ ...

(.venv) PS C:\Users\ROBERTSCIENCE\Documents\Tarea_M21-CD – robertscience\notebooks> start Tarea_M21-CD_robertscience.html

File

Edit

Selection

View

Go

Run

...

←

→

Tarea M21-CD – robertscience [Administrator]

...

...

...

...

Tarea_M21-CD_robertscience.ipynb

X

Tarea_M21-CD_robertscience.html

3

Tarea_M21-CD_robertscience.ipynb

notebooks

>

Tarea_M21-CD_robertscience.ipynb

>

M↓ Tarea M21-CD – Análisis de Clasificación con K Vecinos Más Cercanos (KNN)

>

M↓ Preparación de los datos

Generate

+

Code

+

Markdown

|

Run All

↺

Restart

✖

Clear All Outputs

|

Jupyter Variables

≡

Outline

...

.venv (Pyt

Esta separación es necesaria para entrenar y evaluar el modelo de clasificación de manera adecuada.

▶

▼

```
from sklearn.model_selection import train_test_split

# División del dataset en entrenamiento y prueba
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.3, random_state=42, stratify=y
)

X_train.shape, X_test.shape
```

[10]

✓

1.0s

...

((10499, 18), (4500, 18))

División del conjunto de datos

El conjunto de datos se dividió en un 70% para entrenamiento y un 30% para prueba. Se utilizó el parámetro `stratify=y` para preservar la proporción original de clases en ambos subconjuntos.

Esta estrategia permite evaluar el desempeño del modelo sobre datos no vistos, reduciendo el riesgo de sobreajuste.

PROBLEMS 3

OUTPUT

DEBUG CONSOLE

TERMINAL

PORTS

JUPYTER

QUERY RESULTS

msedge - notebooks

+

▼

✖

...

(.venv) PS C:\Users\ROBERTSCIENCE\Documents\Tarea_M21-CD – robertscience\notebooks> start Tarea_M21-CD_robertscience.html

FileEditSelectionViewGoRun...<=>Tarea M21-CD – robertscience [Administrator]🗨️⌵

Tarea_M21-CD_robertscience.ipynb ×<>Tarea_M21-CD_robertscience.html 3Tarea_M21-CD_robertscience.ipynb

notebooks > Tarea_M21-CD_robertscience.ipynb > M↓ Tarea M21-CD – Análisis de Clasificación con K Vecinos Más Cercanos (KNN) > M↓ Preparación de los datos

Generate + Code + Markdown | Run All ⌂ Restart ⌵ Clear All Outputs | Jupyter Variables ⌵ Outline ...📄 .venv (Pyt

clases en ambos subconjuntos.

Esta estrategia permite evaluar el desempeño del modelo sobre datos no vistos, reduciendo el riesgo de sobreajuste.

▶

from sklearn.preprocessing import StandardScaler

Escalado de variables numéricas

scaler = StandardScaler()

X_train_scaled = scaler.fit_transform(X_train)

X_test_scaled = scaler.transform(X_test)

[11] ✓ 0.0s

Escalado de variables

Se aplicó un proceso de estandarización a las variables predictoras utilizando `StandardScaler`. Este procedimiento ajusta las variables para que tengan media cero y desviación estándar uno.

El escalado es indispensable en el algoritmo KNN, ya que este se basa en el cálculo de distancias entre observaciones. Sin este paso, las variables con mayor escala podrían dominar el proceso de clasificación.

PROBLEMS 3OUTPUTDEBUG CONSOLETERMINALPORTSJUPYTERQUERY RESULTSmsedge - notebooks + ⌵ 🗑️ ...

(.venv) PS C:\Users\ROBERTSCIENCE\Documents\Tarea_M21-CD – robertscience\notebooks> start Tarea_M21-CD_robertscience.html

File

Edit

Selection

View

Go

Run

...

←

→

Tarea M21-CD – robertscience [Administrator]

🗨

🔍

📄

📁

🔗

🔧

📦

🧪

📱

🔔

👤

⚙️

Tarea_M21-CD_robertscience.ipynb

✕

<>

Tarea_M21-CD_robertscience.html

3

Tarea_M21-CD_robertscience.ipynb

✕

notebooks

>

Tarea_M21-CD_robertscience.ipynb

>

M↓ Tarea M21-CD – Análisis de Clasificación con K Vecinos Más Cercanos (KNN)

>

M↓ Preparación de los datos

🔧 Generate

+

Code

+

Markdown

|

🎬 Run All

↺ Restart

✖ Clear All Outputs

|

📋 Jupyter Variables

☰ Outline

...

📄 .venv (Pyt

Entrenamiento del modelo KNN

En esta sección se entrena el modelo de K Vecinos Más Cercanos (KNN) evaluando distintos valores del parámetro k. El objetivo es identificar el valor de k que ma
desempeño predictivo del modelo.

Se analizarán valores de k desde 1 hasta 20 y se compararán diversas métricas de clasificación para respaldar la selección del valor óptimo.

▶

```
from sklearn.neighbors import KNeighborsClassifier
from sklearn.metrics import accuracy_score, precision_score, recall_score, f1_score

# Listas para almacenar métricas
k_values = range(1, 21)
accuracy = []
precision = []
recall = []
f1 = []

# Entrenamiento y evaluación para cada valor de k
for k in k_values:
    knn = KNeighborsClassifier(n_neighbors=k)
    knn.fit(X_train_scaled, y_train)
```

[12]

✓

6.6s

PROBLEMS 3

OUTPUT

DEBUG CONSOLE

TERMINAL

PORTS

JUPYTER

QUERY RESULTS

msedge - notebooks

+

🗨

🗑

...

(.venv) PS C:\Users\ROBERTSCIENCE\Documents\Tarea_M21-CD – robertscience\notebooks> start Tarea_M21-CD_robertscience.html

FileEditSelectionViewGoRun...Tarea M21-CD – robertscience [Administrator]

Tarea_M21-CD_robertscience.ipynbTarea_M21-CD_robertscience.html3Tarea_M21-CD_robertscience.ipynb

notebooks > Tarea_M21-CD_robertscience.ipynb > Tarea M21-CD – Análisis de Clasificación con K Vecinos Más Cercanos (KNN) > Preparación de los datos

GenerateCodeMarkdownRun AllRestartClear All OutputsJupyter VariablesOutline.venv (Python 3.8.10)

```
y_pred = knn.predict(X_test_scaled)

accuracy.append(accuracy_score(y_test, y_pred))
precision.append(precision_score(y_test, y_pred))
recall.append(recall_score(y_test, y_pred))
f1.append(f1_score(y_test, y_pred))
```

[12] ✓ 6.6s

▶

```
# Creación de la tabla de resultados
results_knn = pd.DataFrame({
    'k': k_values,
    'Accuracy': accuracy,
    'Precision': precision,
    'Recall': recall,
    'F1-Score': f1
})

results_knn
```

[13] ✓ 0.0s

...

	k	Accuracy	Precision	Recall	F1-Score
0	1	0.962000	0.893357	0.954248	0.922799

PROBLEMS3OUTPUTDEBUG CONSOLETERMINALPORTSJUPYTERQUERY RESULTSmsedge - notebooks

(.venv) PS C:\Users\ROBERTSCIENCE\Documents\Tarea_M21-CD – robertscience\notebooks> start Tarea_M21-CD_robertscience.html

File

Edit

Selection

View

Go

Run

...

←

→

Tarea M21-CD – robertscience [Administrator]

Tarea_M21-CD_robertscience.ipynb

X

<> Tarea_M21-CD_robertscience.html 3

Tarea_M21-CD_robertscience.ipynb

notebooks > Tarea_M21-CD_robertscience.ipynb > M↓ Tarea M21-CD – Análisis de Clasificación con K Vecinos Más Cercanos (KNN) > M↓ Preparación de los datos

Generate

+ Code

+ Markdown

|

Run All

Restart

Clear All Outputs

|

Jupyter Variables

Outline

...

.venv (Pyt

...

k

Accuracy

Precision

Recall

F1-Score

0

1

0.962000

0.893357

0.954248

0.922799

1

2

0.958889

0.919508

0.906629

0.913023

2

3

0.946444

0.865961

0.916900

0.890703

3

4

0.947333

0.894886

0.882353

0.888575

4

5

0.939778

0.859712

0.892624

0.875859

5

6

0.945556

0.887430

0.883287

0.885353

6

7

0.941333

0.868493

0.887955

0.878116

7

8

0.942889

0.878253

0.882353

0.880298

8

9

0.939778

0.862319

0.888889

0.875402

9

10

0.941778

0.874191

0.882353

0.878253

10

11

0.938222

0.858824

0.886088

0.872243

11

12

0.937556

0.866419

0.872082

0.869242

12

13

0.935556

0.855971

0.876751

0.866236

13

14

0.936889

0.863343

0.873016

0.868152

14

15

0.933778

0.850408

0.875817

0.862925

15

16

0.935111

0.855059

0.875817

0.865314

16

17

0.932222

0.844424

0.876751

0.860284

17

18

0.933778

0.850408

0.875817

0.862925

PROBLEMS 3

OUTPUT

DEBUG CONSOLE

TERMINAL

PORTS

JUPYTER

QUERY RESULTS

msedge - notebooks + ▾

(.venv) PS C:\Users\ROBERTSCIENCE\Documents\Tarea M21-CD – robertscience\notebooks> start Tarea M21-CD_robertscience.html

File

Edit

Selection

View

Go

Run

...

←

→

Q

Tarea M21-CD – robertscience [Administrator]

–

Tarea_M21-CD_robertscience.ipynb X

Tarea_M21-CD_robertscience.html 3

Tarea_M21-CD_robertscience.ipynb

notebooks > Tarea_M21-CD_robertscience.ipynb > M↓ Tarea M21-CD – Análisis de Clasificación con K Vecinos Más Cercanos (KNN) > M↓ Preparación de los datos

Generate

+ Code

+ Markdown

|

Run All

Restart

|

Clear All Outputs

|

Jupyter Variables

|

Outline

...

.venv (Pyt

16	17	0.932222	0.844424	0.876751	0.860284
17	18	0.933778	0.850408	0.875817	0.862925
18	19	0.932444	0.845807	0.875817	0.860550
19	20	0.928444	0.847725	0.852474	0.850093

✓

Análisis comparativo de métricas para distintos valores de k

La tabla anterior muestra el desempeño del modelo KNN para valores de k entre 1 y 20, evaluado mediante métricas de clasificación como exactitud (accuracy), precisión (precision), recall y F1-score.

Se observa que valores bajos de k tienden a producir modelos más sensibles al ruido, mientras que valores más altos generan modelos más estables pero con menor capacidad de discriminación. El valor óptimo de k se selecciona considerando un equilibrio entre las métricas, priorizando un desempeño consistente y una adecuada capacidad de generalización sobre el conjunto de prueba.

```
# Selección de la k óptima basada en el mayor F1-score
best_k = results_knn.loc[results_knn['F1-Score'].idxmax(), 'k']
best_k
```

[14]

✓

0.0s

PROBLEMS 3

OUTPUT

DEBUG CONSOLE

TERMINAL

PORTS

JUPYTER

QUERY RESULTS

msedge - notebooks

+

✓

...

(.venv) PS C:\Users\ROBERTSCIENCE\Documents\Tarea_M21-CD – robertscience\notebooks> start Tarea_M21-CD_robertscience.html

FileEditSelectionViewGoRun<Tarea M21-CD – robertscience [Administrator]>

Tarea_M21-CD_robertscience.ipynbTarea_M21-CD_robertscience.html 3Tarea_M21-CD_robertscience.ipynb

notebooks > Tarea_M21-CD_robertscience.ipynb > M↓ Tarea M21-CD – Análisis de Clasificación con K Vecinos Más Cercanos (KNN) > M↓ Matriz de confusión del modelo KNN óptimo

Generate + Code + Markdown | Run All Restart Clear All Outputs Jupyter Variables Outlinevenv (Python 3.10.6)

```
# Selección de la k óptima basada en el mayor F1-score
best_k = results_knn.loc[results_knn['F1-Score'].idxmax(), 'k']
best_k
```

[30] ✓ 0.0s

... np.int64(1)

```
best_k = results_knn.loc[results_knn['F1-Score'].idxmax(), 'k']
best_k
```

[31] ✓ 0.0s

... np.int64(1)


Selección del valor óptimo de k

Con base en la comparación de métricas, se selecciona $k = 1$ como el valor óptimo para el modelo KNN, ya que presenta el mejor equilibrio entre precisión y recall, reflejado en el mayor valor de F1-score.

Este resultado indica que el modelo logra identificar adecuadamente a los empleados que abandonan la empresa, minimizando tanto los falsos positivos como los falsos negativos.

PROBLEMS 3 OUTPUT DEBUG CONSOLE TERMINAL PORTS JUPYTER QUERY RESULTSmsedge - notebooks + -

(.venv) PS C:\Users\ROBERTSCIENCE\Documents\Tarea M21-CD – robertscience\notebooks> start Tarea_M21-CD_robertscience.html



FileEditSelectionViewGoRun<=>Tarea M21-CD – robertscience [Administrator]

Tarea_M21-CD_robertscience.ipynbTarea_M21-CD_robertscience.html 3Tarea_M21-CD_robertscience.ipynb

notebooks > Tarea_M21-CD_robertscience.ipynb > M↓ Tarea M21-CD – Análisis de Clasificación con K Vecinos Más Cercanos (KNN) > M↓ Preparación de los datos

Generate+ Code+ MarkdownRun AllRestartClear All OutputsJupyter VariablesOutline... .venv (Pyt

▶

plt.title('Matriz de Confusión - KNN óptimo')
plt.show()

[16] ✓ 0.1s

Matriz de Confusión - KNN óptimo

	Predicción 0	Predicción 1
Valor real 0	3307	122
Valor real 1	49	1022

PROBLEMS 3OUTPUTDEBUG CONSOLETERMINALPORTSJUPYTERQUERY RESULTSmsedge - notebooks+🗑️...

(.venv) PS C:\Users\ROBERTSCIENCE\Documents\Tarea_M21-CD – robertscience\notebooks> start Tarea_M21-CD_robertscience.html

File

Edit

Selection

View

Go

Run

⋮

←

→

🔍

Tarea M21-CD – robertscience [Administrator]

🗨

📄

📄

📄

—

Tarea_M21-CD_robertscience.ipynb

✕

<>

Tarea_M21-CD_robertscience.html

3

Tarea_M21-CD_robertscience.ipynb

🔗

notebooks >

Tarea_M21-CD_robertscience.ipynb >

M↓ Tarea M21-CD – Análisis de Clasificación con K Vecinos Más Cercanos (KNN) >

M↓ Preparación de los datos

🔧 Generate

⊕ Code

⊕ Markdown

|

🎬 Run All

🔄 Restart

✖ Clear All Outputs

|

📄 Jupyter Variables

☰ Outline

⋮

📄 .venv (Pyt

Interpretación de la matriz de confusión

La matriz de confusión permite interpretar el desempeño del modelo KNN óptimo en términos de clasificaciones correctas e incorrectas:

- **Verdaderos negativos (TN):** empleados que no abandonaron la empresa y fueron correctamente clasificados como tales.
- **Verdaderos positivos (TP):** empleados que abandonaron la empresa y fueron correctamente identificados por el modelo.
- **Falsos positivos (FP):** empleados que permanecieron en la empresa pero fueron clasificados incorrectamente como si hubieran abandonado.
- **Falsos negativos (FN):** empleados que abandonaron la empresa pero no fueron detectados por el modelo.

Se observa que el modelo presenta una adecuada capacidad para identificar a los empleados que abandonan la empresa, aunque aún existen errores de clasificación que podrían impactar decisiones operativas si no se consideran con cautela.

Curva ROC del modelo KNN óptimo

La curva ROC (Receiver Operating Characteristic) permite evaluar la capacidad del modelo para discriminar entre las dos clases, considerando la relación entre la tasa de verdaderos positivos y la tasa de falsos positivos para distintos umbrales de decisión.

```
from sklearn.metrics import roc_curve, auc
```

[17]

✓ 0.2s

PROBLEMS 3

OUTPUT

DEBUG CONSOLE

TERMINAL

PORTS

JUPYTER

QUERY RESULTS

msedge - notebooks

+

📄

🗑

⋮

(.venv) PS C:\Users\ROBERTSCIENCE\Documents\Tarea_M21-CD – robertscience\notebooks>

start Tarea_M21-CD_robertscience.html

FileEditSelectionViewGoRun<Tarea M21-CD – robertscience [Administrator]

Tarea_M21-CD_robertscience.ipynbTarea_M21-CD_robertscience.html3Tarea_M21-CD_robertscience.ipynb

notebooks > Tarea_M21-CD_robertscience.ipynb > M↓ Tarea M21-CD – Análisis de Clasificación con K Vecinos Más Cercanos (KNN) > M↓ Preparación de los datos

GenerateCodeMarkdownRun AllRestartClear All OutputsJupyter VariablesOutline.venv (Python 3.8.5)

```
from sklearn.metrics import roc_curve, auc


# Probabilidades para la clase positiva
y_prob = knn_optimo.predict_proba(X_test_scaled)[: , 1]

# Cálculo de la curva ROC
fpr, tpr, thresholds = roc_curve(y_test, y_prob)
roc_auc = auc(fpr, tpr)

# Gráfica de la curva ROC
plt.figure(figsize=(6, 4))
plt.plot(fpr, tpr, label=f'AUC = {roc_auc:.3f}')
plt.plot([0, 1], [0, 1], linestyle='--')
plt.xlabel('Tasa de Falsos Positivos')
plt.ylabel('Tasa de Verdaderos Positivos')
plt.title('Curva ROC - KNN óptimo')
plt.legend()
plt.show()
```

[17] ✓ 0.2s

Curva ROC - KNN óptimo



PROBLEMS 3OUTPUTDEBUG CONSOLETERMINALPORTSJUPYTERQUERY RESULTSmsedge - notebooks

(.venv) PS C:\Users\ROBERTSCIENCE\Documents\Tarea_M21-CD – robertscience\notebooks> start Tarea_M21-CD_robertscience.html



FileEditSelectionViewGoRun

Tarea M21-CD – robertscience [Administrator]

Tarea_M21-CD_robertscience.ipynb

Tarea_M21-CD_robertscience.html 3

Tarea_M21-CD_robertscience.ipynb

notebooks > Tarea_M21-CD_robertscience.ipynb > Tarea M21-CD – Análisis de Clasificación con K Vecinos Más Cercanos (KNN) > Preparación de los datos

GenerateCodeMarkdownRun AllRestartClear All OutputsJupyter VariablesOutline

.venv (Python 3.10.6)

Interpretación de la curva ROC

La curva ROC obtenida muestra el desempeño global del modelo KNN óptimo para discriminar entre empleados que abandonan y los que permanecen en la empresa. El valor del área bajo la curva (AUC) indica la probabilidad de que el modelo asigne una mayor probabilidad a un empleado que abandona la empresa frente a uno que permanece.

Un valor de AUC cercano a 1 refleja un excelente poder discriminativo, mientras que un valor cercano a 0.5 indicaría un desempeño similar al azar. En este caso, el modelo presenta una capacidad predictiva adecuada para apoyar procesos de toma de decisiones en el área de recursos humanos.

Conclusiones generales

En esta práctica se desarrolló un modelo de clasificación utilizando el algoritmo de K Vecinos Más Cercanos (KNN) con el objetivo de predecir si un empleado abandona o no la empresa, a partir de variables relacionadas con satisfacción laboral, desempeño, carga de trabajo y características contractuales.

A lo largo del análisis se realizó una preparación adecuada de los datos, incluyendo la recodificación de variables categóricas y el escalado de variables numéricas, fundamentales para garantizar el correcto funcionamiento del algoritmo KNN, el cual se basa en el cálculo de distancias entre observaciones.

La evaluación de distintos valores del parámetro k permitió identificar una configuración óptima del modelo, respaldada por métricas de clasificación como accuracy, precision, recall y F1-score. Los resultados obtenidos muestran que el modelo es capaz de identificar de manera adecuada patrones asociados a la rotación de personal, aunque presenta ciertas limitaciones inherentes a la complejidad del fenómeno analizado.

PROBLEMS 3OUTPUTDEBUG CONSOLETERMINALPORTSJUPYTERQUERY RESULTS

msedge - notebooks

(.venv) PS C:\Users\ROBERTSCIENCE\Documents\Tarea_M21-CD – robertscience\notebooks> start Tarea_M21-CD_robertscience.html

FileEditSelectionViewGoRun...Tarea M21-CD – robertscience [Administrator]

Tarea_M21-CD_robertscience.ipynbTarea_M21-CD_robertscience.html3Tarea_M21-CD_robertscience.ipynb

notebooks > Tarea_M21-CD_robertscience.ipynb > M↓ Tarea M21-CD – Análisis de Clasificación con K Vecinos Más Cercanos (KNN) > M↓ Preparación de los datos

GenerateCodeMarkdownRun AllRestartClear All OutputsJupyter VariablesOutline.venv (Pyt

Conclusiones técnicas del modelo

El análisis de la matriz de confusión evidenció que el modelo KNN logra una buena clasificación de los empleados que permanecen en la empresa, así como una clasificación razonable para identificar a aquellos que abandonan la organización. No obstante, se observan falsos positivos y falsos negativos, los cuales deben ser considerados cuidadosamente en un contexto real de toma de decisiones.

La curva ROC y el valor del AUC confirman que el modelo presenta una capacidad discriminativa adecuada, superior al azar, lo que valida su uso como herramienta de apoyo analítico. Sin embargo, debido a la naturaleza del algoritmo KNN, el desempeño del modelo puede verse afectado por la dimensionalidad de los datos y la presencia de variables altamente correlacionadas.

GenerateCodeMarkdown

Implicaciones para el área de Recursos Humanos

Desde una perspectiva aplicada, el modelo desarrollado puede ser utilizado como un sistema de apoyo para identificar empleados con mayor probabilidad de abandonar la empresa. Esto permitiría al área de recursos humanos implementar estrategias preventivas, como planes de retención, mejoras en condiciones laborales o programas de desarrollo profesional.

Es importante destacar que los resultados del modelo no deben ser utilizados de manera aislada, sino como complemento de análisis cualitativos y del conocimiento experto del área, con el fin de evitar decisiones sesgadas o incorrectas.

PROBLEMS3OUTPUTDEBUG CONSOLETERMINALPORTSJUPYTERQUERY RESULTS

msedge - notebooks

(.venv) PS C:\Users\ROBERTSCIENCE\Documents\Tarea_M21-CD – robertscience\notebooks> start Tarea_M21-CD_robertscience.html

FileEditSelectionViewGoRun...←→Tarea M21-CD – robertscience [Administrator]

Tarea_M21-CD_robertscience.ipynb ×Tarea_M21-CD_robertscience.html 3Tarea_M21-CD_robertscience.ipynb

notebooks > Tarea_M21-CD_robertscience.ipynb > M↓ Tarea M21-CD – Análisis de Clasificación con K Vecinos Más Cercanos (KNN) > M↓ Preparación de los datos

Generate + Code + Markdown | Run All Restart Clear All Outputs | Jupyter Variables Outlinevenv (Python 3.8.10)

apoyo humano. Sin embargo, debido a la naturaleza del algoritmo KNN, el desempeño del modelo puede verse afectado por la dimensionalidad de los datos y la presencia de variables altamente correlacionadas.

Implicaciones para el área de Recursos Humanos

Desde una perspectiva aplicada, el modelo desarrollado puede ser utilizado como un sistema de apoyo para identificar empleados con mayor probabilidad de abandonar la empresa. Esto permitiría al área de recursos humanos implementar estrategias preventivas, como planes de retención, mejoras en condiciones laborales o programas de desarrollo profesional.

Es importante destacar que los resultados del modelo no deben ser utilizados de manera aislada, sino como complemento de análisis cualitativos y del conocimiento experto del área, con el fin de evitar decisiones sesgadas o incorrectas.

Limitaciones y trabajo futuro

Entre las principales limitaciones del análisis se encuentra la sensibilidad del algoritmo KNN al escalado de los datos y al valor del parámetro k. Asimismo, el modelo no proporciona interpretabilidad directa sobre la importancia individual de cada variable.

Como trabajo futuro, se recomienda comparar el desempeño del modelo KNN con otros algoritmos de clasificación, como regresión logística, árboles de decisión o random forest, así como explorar técnicas de balanceo de clases para mejorar la detección de empleados que abandonan la empresa.

PROBLEMS 3OUTPUTDEBUG CONSOLETERMINALPORTSJUPYTERQUERY RESULTSmsedge - notebooks + -

(.venv) PS C:\Users\ROBERTSCIENCE\Documents\Tarea M21-CD – robertscience\notebooks> start Tarea_M21-CD_robertscience.html