

1

🔍

🔗

⚙️

📁

🧪

🖨️

📄

🔊

⚙️

File Edit Selection View Go Run ...

← →

Tarea M22-CD -RobertScience [Administrator]

🗨️

🔍

📄

📄

📄

—

🔍

Tarea_M22-CD_robertscience.ipynb

Tarea_M22-CD_robertscience.ipynb

🔍

notebooks > Tarea_M22-CD_robertscience.ipynb > M22 Tarea M22-CD – Análisis de Clasificación con Máquinas de Soporte Vectorial (SVM) > M22 Conclusiones finales

🔍 Generate + Code + Markdown | ▶ Run All ↺ Restart 🗑️ Clear All Outputs | 📄 Jupyter Variables 📄 Outline ...

📄 .venv (Python 3.10.6)

▶

```
# Distribución porcentual de la variable objetivo
df['left'].value_counts(normalize=True) * 100
```

[7] ✓ 0.0s

... left

0	76.191746
1	23.808254

Name: proportion, dtype: float64

El análisis de la variable objetivo muestra que la base de datos presenta un desbalance entre las clases, siendo mayor el número de empleados que permanecen en la empresa en comparación con aquellos que la abandonan. Este comportamiento es común en problemas de rotación de personal y debe considerarse al evaluar el desempeño de los modelos de clasificación, ya que métricas como la precisión pueden verse influenciadas por dicho desbalance.

Preparación de los datos para el modelado

Antes de entrenar los modelos de Máquinas de Soporte Vectorial, es necesario preparar el conjunto de datos. Esta etapa incluye la transformación de variables categóricas, la separación de la variable objetivo y el escalado de las variables numéricas.

La correcta preparación de los datos es especialmente importante en modelos SVM, ya que estos son sensibles a la escala de las variables.

la separación de la variable objetivo y el escalado de las variables numéricas.

La correcta preparación de los datos es especialmente importante en modelos SVM, ya que estos son sensibles a la escala de las variables.

```
# Separación de variables predictoras y variable objetivo
X = df.drop('left', axis=1)
y = df['left']
```

[8]	✓	0.0s
-----	---	------

 Generate  Code  Markdown

```
# Codificación de variables categóricas
X_encoded = pd.get_dummies(X, drop_first=True)
```

[9] ✓ 0.0s

La transformación de las variables categóricas mediante codificación permite convertir la información cualitativa en un formato numérico adecuado para los modelos de Machine Learning. Con esto, el conjunto de datos queda listo para aplicar técnicas de escalado y posteriormente entrenar los modelos de clasificación.

Escalado de variables y partición del conjunto de datos

Las Máquinas de Soporte Vectorial son sensibles a la escala de las variables, por lo que es necesario aplicar un proceso de estandarización antes de entrenar los modelos. El escalado permite que todas las variables contribuyan de manera equilibrada al proceso de aprendizaje.



 Generate
 Code
 Markdown
 Run All
 Restart
 Clear All Outputs
 Jupyter Variables
 Outline
 ...

[12] ✓ 0.0s

Generate + Code + Markdown

```
from sklearn.svm import SVC
from sklearn.metrics import classification_report, confusion_matrix
import seaborn as sns
import matplotlib.pyplot as plt
```


File Edit Selection View Go Run ... Tarea M22-CD -RobertScience [Administrator]

Tarea_M22-CD_robertscience.ipynb Tarea_M22-CD_robertscience.ipynb

notebooks > Tarea_M22-CD_robertscience.ipynb > M22 Tarea M22-CD - Análisis de Clasificación con Máquinas de Soporte Vectorial (SVM) > M22 Conclusiones finales

Generate + Code + Markdown Run All Restart Clear All Outputs Jupyter Variables Outlinevenv (Python 3.10.6)

```
# Predicciones con el modelo lineal
y_pred_linear = svm_linear.predict(X_test_scaled)
```

[15] ✓ 0.2s

Generate + Code + Markdown

```
# Matriz de confusión
cm_linear = confusion_matrix(y_test, y_pred_linear)
cm_linear
```

[16] ✓ 0.0s

```
array([[3202, 227],
       [ 789, 282]])
```

```
# Mapa de calor de la matriz de confusión
plt.figure()
sns.heatmap(cm_linear, annot=True, fmt='d', cmap='Blues')
plt.xlabel('Predicción')
plt.ylabel('Valor real')
plt.title('Matriz de confusión - SVM Kernel Lineal')
plt.show()
```

[17] ✓ 0.2s

Matriz de confusión - SVM Kernel Lineal

FileEditSelectionViewGoRun

Tarea M22-CD –RobertScience [Administrator]

1

Tarea_M22-CD_robertscience.ipynb

Tarea_M22-CD_robertscience.ipynb

notebooks > Tarea_M22-CD_robertscience.ipynb > Tarea M22-CD – Análisis de Clasificación con Máquinas de Soporte Vectorial (SVM) > Conclusiones finales

GenerateCodeMarkdownRun AllRestartClear All OutputsJupyter VariablesOutline

.venv (Python 3.10.6)

[17] ✓ 0.2s

...

Matriz de confusión - SVM Kernel Lineal

	Predicción 0	Predicción 1
Valor real 0	3202	227
Valor real 1	789	282

```
print(classification_report(y_test, y_pred_lineal))
```


1

🔍

🔗

🔧

📁

🧪

🖨️

📱

🔄

👤

⚙️

File Edit Selection View Go Run ...

← →

Tarea M22-CD –RobertScience [Administrator]

🗨️

🔖 📄 📄 📄 –

Tarea_M22-CD_robertscience.ipynb • Tarea_M22-CD_robertscience.ipynb

notebooks > Tarea_M22-CD_robertscience.ipynb > M Tarea M22-CD – Análisis de Clasificación con Máquinas de Soporte Vectorial (SVM) > M Conclusiones finales

🔧 Generate + Code + Markdown | 🎬 Run All 🔄 Restart 🗑️ Clear All Outputs | 📄 Jupyter Variables 📖 Outline ...

📄 .venv (Python 3.10.12)

🎬 Generate + Code + Markdown

▶

Reporte de clasificación
print(classification_report(y_test, y_pred_linear))

[18] ✓ 0.0s

...

	precision	recall	f1-score	support
0	0.80	0.93	0.86	3429
1	0.55	0.26	0.36	1071
accuracy			0.77	4500
macro avg	0.68	0.60	0.61	4500
weighted avg	0.74	0.77	0.74	4500

Los resultados del modelo SVM con kernel lineal muestran el desempeño del clasificador al separar las clases mediante una frontera lineal. A partir de la matriz de confusión y el reporte de clasificación es posible evaluar la capacidad del modelo para identificar correctamente a los empleados que abandonan la empresa y aquellos que permanecen en ella.

Este modelo sirve como referencia inicial para comparar el impacto de kernels más complejos en la capacidad predictiva del algoritmo.

Modelo SVM con kernel polinomial

En este segundo modelo se utiliza una Máquina de Soporte Vectorial con kernel polinomial. Este tipo de kernel permite capturar relaciones no lineales entre las variables al proyectar los datos a un espacio de mayor dimensión. Su uso resulta útil cuando la separación entre clases no puede representarse adecuadamente mediante una frontera lineal.

[19] ✓ 0.7s

[20] ✓ 0.1s

```
# Matriz de confusión
cm_poly = confusion matrix(y_test, y_pred_poly)
```

1

File

Edit

Selection

View

Go

Run

...

←

→

Tarea M22-CD –RobertScience [Administrator]

🗨

🔍

📄

📄

📄

📄

—

⚙

Tarea_M22-CD_robertscience.ipynb

Tarea_M22-CD_robertscience.ipynb

⚙

notebooks > Tarea_M22-CD_robertscience.ipynb > M Tarea M22-CD – Análisis de Clasificación con Máquinas de Soporte Vectorial (SVM) > M Conclusiones finales

🔍

Generate

+ Code

+ Markdown

▶ Run All

🔄 Restart

🗑 Clear All Outputs

📄 Jupyter Variables

☰ Outline

...

📄 .venv (Python 3.10.6)

▶

▼

Matriz de confusión
cm_poly = confusion_matrix(y_test, y_pred_poly)
cm_poly

[21] ✓ 0.0s

... array([[3330, 99],
[179, 892]])

Generate

+ Code

+ Markdown

Mapa de calor de la matriz de confusión
plt.figure()
sns.heatmap(cm_poly, annot=True, fmt='d', cmap='Blues')
plt.xlabel('Predicción')
plt.ylabel('Valor real')
plt.title('Matriz de confusión - SVM Kernel Polinomial')
plt.show()

[22] ✓ 0.0s

...

Matriz de confusión - SVM Kernel Polinomial


0

3330

99

3000

2500



FileEditSelectionViewGoRun

Tarea M22-CD –RobertScience [Administrator]

Tarea_M22-CD_robertscience.ipynb

Tarea_M22-CD_robertscience.ipynb

notebooks > Tarea_M22-CD_robertscience.ipynb > M22 Tarea M22-CD – Análisis de Clasificación con Máquinas de Soporte Vectorial (SVM) > M22 Conclusiones finales

GenerateCodeMarkdownRun AllRestartClear All OutputsJupyter VariablesOutline

.venv (Python 3.10.11)

Reporte de clasificación
print(classification_report(y_test, y_pred_poly))

[23] ✓ 0.0s

	precision	recall	f1-score	support
0	0.95	0.97	0.96	3429
1	0.90	0.83	0.87	1071
accuracy			0.94	4500
macro avg	0.92	0.90	0.91	4500
weighted avg	0.94	0.94	0.94	4500

El modelo SVM con kernel polinomial permite capturar relaciones más complejas entre las variables en comparación con el kernel lineal. A partir de los resultados obtenidos, se puede evaluar si la incorporación de no linealidades mejora la capacidad del modelo para clasificar correctamente a los empleados según su probabilidad de abandono.

Este modelo se analiza en conjunto con los demás kernels para determinar si su mayor complejidad se traduce en un mejor desempeño predictivo.

Modelo SVM con kernel radial (RBF)

En este modelo se utiliza una Máquina de Soporte Vectorial con kernel radial (RBF). Este kernel es ampliamente utilizado en problemas de clasificación, ya que permi

En este modelo se utiliza una Máquina de Soporte Vectorial con kernel radial (RBF). Este kernel es ampliamente utilizado en problemas de clasificación, ya que permite modelar fronteras de decisión altamente no lineales y adaptarse mejor a conjuntos de datos complejos.

El kernel RBF suele ofrecer un buen balance entre flexibilidad y capacidad de generalización, por lo que resulta un candidato natural para comparar con los modelos lineales y polinomial.

[24] ✓ 0.6s

```
# Predicciones con el modelo RBF
y_pred_rbf = svm_rbf.predict(X_test_scaled)
```

[25] ✓ 0.4s

File Edit Selection View Go Run ... Tarea M22-CD - RobertScience [Administrator]

Tarea_M22-CD_robertscience.ipynb • Tarea_M22-CD_robertscience.ipynb

notebooks > Tarea_M22-CD_robertscience.ipynb > M22 Tarea M22-CD - Análisis de Clasificación con Máquinas de Soporte Vectorial (SVM) > M22 Conclusiones finales

Generate + Code + Markdown | Run All Restart Clear All Outputs | Jupyter Variables Outlinevenv (Python 3.10.6)

```
# Predicciones con el modelo RBF
y_pred_rbf = svm_rbf.predict(X_test_scaled)
```

[25] ✓ 0.4s

```
# Matriz de confusión
cm_rbf = confusion_matrix(y_test, y_pred_rbf)
cm_rbf
```


[26] ✓ 0.0s

```
... array([[3324, 105],
          [ 108, 963]])
```

```
# Mapa de calor de la matriz de confusión
plt.figure()
sns.heatmap(cm_rbf, annot=True, fmt='d', cmap='Blues')
plt.xlabel('Predicción')
plt.ylabel('Valor real')
plt.title('Matriz de confusión - SVM Kernel RBF')
plt.show()
```

[27] ✓ 0.0s

Matriz de confusión - SVM Kernel RBF



FileEditSelectionViewGoRun

Tarea M22-CD –RobertScience [Administrator]

Tarea_M22-CD_robertscience.ipynb

Tarea_M22-CD_robertscience.ipynb

notebooks > Tarea_M22-CD_robertscience.ipynb > M↓ Tarea M22-CD – Análisis de Clasificación con Máquinas de Soporte Vectorial (SVM) > M↓ Conclusiones finales

GenerateCodeMarkdownRun AllRestartClear All OutputsJupyter VariablesOutline

Reporte de clasificación
print(classification_report(y_test, y_pred_rbf))

[28] ✓ 0.0s

	precision	recall	f1-score	support
0	0.97	0.97	0.97	3429
1	0.90	0.90	0.90	1071
accuracy			0.95	4500
macro avg	0.94	0.93	0.93	4500
weighted avg	0.95	0.95	0.95	4500

El modelo SVM con kernel RBF muestra un comportamiento más flexible al permitir fronteras de decisión no lineales. A partir de los resultados obtenidos se puede ver si este enfoque mejora la identificación de empleados con riesgo de abandono, en comparación con los kernels lineal y polinomial.

El desempeño de este modelo se analizará de manera conjunta con los demás kernels para seleccionar la alternativa más adecuada para el problema planteado.

Modelo SVM con kernel sigmoide

En este modelo se emplea una Máquina de Soporte Vectorial con kernel sigmoide. Este kernel está inspirado en el comportamiento de funciones de activación utili

FileEditSelectionViewGoRun...←→Tarea M22-CD -RobertScience [Administrator]

Tarea_M22-CD_robertscience.ipynb • Tarea_M22-CD_robertscience.ipynb

notebooks > Tarea_M22-CD_robertscience.ipynb > M↓ Tarea M22-CD – Análisis de Clasificación con Máquinas de Soporte Vectorial (SVM) > M↓ Conclusiones finales

Generate + Code + Markdown | Run All Restart Clear All Outputs | Jupyter Variables Outlinevenv (Python 3.10.6)

Modelo SVM con kernel sigmoide

En este modelo se emplea una Máquina de Soporte Vectorial con kernel sigmoide. Este kernel está inspirado en el comportamiento de funciones de activación utilizadas en redes neuronales y puede resultar útil en ciertos contextos específicos.

Su desempeño suele ser más sensible a la escala de los datos y a la selección de parámetros, por lo que su evaluación permite completar el análisis comparativo entre distintos tipos de kernel.

```
[29] ✓ 1.8s
# Entrenamiento del modelo SVM con kernel sigmoide
svm_sigmoid = SVC(kernel='sigmoid', random_state=42)
svm_sigmoid.fit(X_train_scaled, y_train)
```

SVC ⓘ ?

► Parameters

```
[30] ✓ 0.5s
# Predicciones con el modelo sigmoide
y_pred_sigmoid = svm_sigmoid.predict(X_test_scaled)
```


File Edit Selection View Go Run ... Tarea M22-CD -RobertScience [Administrator]

Tarea_M22-CD_robertscience.ipynb Tarea_M22-CD_robertscience.ipynb

notebooks > Tarea_M22-CD_robertscience.ipynb > M22 Tarea M22-CD - Análisis de Clasificación con Máquinas de Soporte Vectorial (SVM) > M22 Conclusiones finales

Generate + Code + Markdown | Run All Restart Clear All Outputs | Jupyter Variables Outlinevenv (Python 3.10.6)

```
[30]: # Predicciones con el modelo sigmoide
y_pred_sigmoide = svm_sigmoide.predict(X_test_scaled)
```

✓ 0.5s

```
[31]: # Matriz de confusión
cm_sigmoide = confusion_matrix(y_test, y_pred_sigmoide)
cm_sigmoide
```


✓ 0.0s

```
array([[2645,  784],
       [ 858,  213]])
```

```
[32]: # Mapa de calor de la matriz de confusión
plt.figure()
sns.heatmap(cm_sigmoide, annot=True, fmt='d', cmap='Blues')
plt.xlabel('Predicción')
plt.ylabel('Valor real')
plt.title('Matriz de confusión - SVM Kernel Sigmoide')
plt.show()
```

✓ 0.0s

Matriz de confusión - SVM Kernel Sigmoide



FileEditSelectionViewGoRun...Tarea M22-CD –RobertScience [Administrator]

Tarea_M22-CD_robertscience.ipynbTarea_M22-CD_robertscience.ipynb

notebooks > Tarea_M22-CD_robertscience.ipynb > M↓ Tarea M22-CD – Análisis de Clasificación con Máquinas de Soporte Vectorial (SVM) > M↓ Conclusiones finales

Generate+ Code+ MarkdownRun AllRestartClear All OutputsJupyter VariablesOutline... .venv (Pyth

▶

Reporte de clasificación
print(classification_report(y_test, y_pred_sigmoid))

[33] ✓ 0.0s

...	precision	recall	f1-score	support
0	0.76	0.77	0.76	3429
1	0.21	0.20	0.21	1071
accuracy			0.64	4500
macro avg	0.48	0.49	0.48	4500
weighted avg	0.63	0.64	0.63	4500

El modelo SVM con kernel sigmoide completa el análisis comparativo entre los distintos enfoques evaluados. A partir de sus métricas de desempeño se puede obs este kernel logra una clasificación adecuada o si presenta limitaciones frente a los modelos previamente analizados.

Los resultados obtenidos se utilizarán para seleccionar el modelo más apropiado considerando precisión, capacidad de generalización e interpretación de errores.

Comparación de modelos SVM

FileEditSelectionViewGoRun...Tarea M22-CD –RobertScience [Administrator]

Tarea_M22-CD_robertscience.ipynbTarea_M22-CD_robertscience.ipynb

notebooks > Tarea_M22-CD_robertscience.ipynb > M↓ Tarea M22-CD – Análisis de Clasificación con Máquinas de Soporte Vectorial (SVM) > M↓ Conclusiones finales

Generate+ Code+ MarkdownRun AllRestartClear All OutputsJupyter VariablesOutline... .venv (Pyth

Comparación de modelos SVM

Con el objetivo de seleccionar el modelo predictivo más adecuado, se evaluaron cuatro configuraciones de Máquinas de Soporte Vectorial, cada una utilizando un kernel distinto: lineal, polinomial, radial (RBF) y sigmoide.

La comparación se realizó considerando las métricas de clasificación obtenidas sobre el conjunto de prueba, tales como precisión (*accuracy*), *recall*, *f1-score* y la distribución de errores reflejada en las matrices de confusión. Este enfoque permite no solo evaluar el desempeño global, sino también analizar la capacidad de cada modelo para identificar correctamente a los empleados que abandonan la empresa.

Selección del modelo predictivo más adecuado

A partir del análisis comparativo de los cuatro modelos evaluados, el modelo SVM con kernel RBF presentó el mejor desempeño predictivo, alcanzando una precisión superior al resto de los enfoques analizados.

Este kernel demostró una mayor capacidad para capturar relaciones no lineales presentes en los datos, lo que se reflejó tanto en la *accuracy* obtenida como en la distribución de errores observada en su matriz de confusión. En particular, el modelo RBF logró identificar de forma más consistente a los empleados que abandonan la empresa, reduciendo errores críticos para la toma de decisiones en el área de Recursos Humanos.

Pronóstico para un empleado con características específicas

Una vez seleccionado el modelo SVM con mejor desempeño, se procede a utilizarlo para realizar un pronóstico individual. Este análisis permite estimar la probabilidad de abandono de un empleado a partir de sus indicadores laborales y constituye una herramienta de apoyo para la toma de decisiones en el área de Recursos Humanos.

```
# Tomar un registro real como plantilla
empleado = X_test.iloc[[0]].copy()

# Modificar valores numéricos para simular un empleado
empleado['satisfaction_level'] = 0.45
empleado['last_evaluation'] = 0.60
empleado['average_monthly_hours'] = 160
empleado['time_spend_company'] = 3

# Asegurar variables binarias
if 'work_accident' in empleado.columns:
    empleado['work_accident'] = 0

if 'promotion_last_5years' in empleado.columns:
    empleado['promotion_last_5years'] = 0

# Escalar
empleado_scaled = scaler.transform(empleado)

# Predicción con SVM RBF
prediccion = svm_rbf.predict(empleado_scaled)
```


FileEditSelectionViewGoRun...Tarea M22-CD -RobertScience [Administrator]

Tarea_M22-CD_robertscience.ipynbTarea_M22-CD_robertscience.ipynb

notebooks > Tarea_M22-CD_robertscience.ipynb > M22-CD - Análisis de Clasificación con Máquinas de Soporte Vectorial (SVM) > Conclusiones finales

GenerateCodeMarkdownRun AllRestartClear All OutputsJupyter VariablesOutline.venv (Python 3.10.12)

```
# Predicción con SVM RBF
prediccion = svm_rbf.predict(empleado_scaled)

prediccion
```

[34] ✓ 0.0s

... array([0])

GenerateCodeMarkdown

▶✎🗑️⋮

Conclusiones finales

El pronóstico obtenido indica que el empleado analizado no presenta una probabilidad significativa de abandonar la empresa. De acuerdo con el modelo SVM seleccionado, su nivel de satisfacción, desempeño y condiciones laborales actuales no lo ubican dentro de un perfil de riesgo.

Este resultado permite concluir que, bajo las condiciones evaluadas, no sería necesario implementar acciones correctivas inmediatas, aunque se recomienda mantener un monitoreo continuo de sus indicadores laborales.

En esta práctica se desarrolló un modelo de clasificación utilizando Máquinas de Soporte Vectorial aplicado a una base de datos de Recursos Humanos, con el objetivo de analizar los factores asociados al abandono de empleados dentro de una organización.

Se evaluaron cuatro configuraciones distintas de SVM mediante el uso de kernels lineal, polinomial, radial (RBF) y sigmoide. A partir de métricas cuantitativas, matrices de confusión y reportes de clasificación, se determinó que el modelo con kernel RBF presentó el mejor desempeño predictivo, logrando una mayor precisión y una mejor identificación de empleados en riesgo de abandono.

FileEditSelectionViewGoRun

Tarea M22-CD –RobertScience [Administrator]

Tarea_M22-CD_robertscience.ipynb

Tarea_M22-CD_robertscience.ipynb

notebooks > Tarea_M22-CD_robertscience.ipynb > M↓ Tarea M22-CD – Análisis de Clasificación con Máquinas de Soporte Vectorial (SVM) > M↓ Conclusiones finales

Generate + Code + Markdown | Run All | Restart | Clear All Outputs | Jupyter Variables | Outline | .venv (Python 3.10.6)

[34] ✓ 0.0s

... array([0])

El pronóstico obtenido indica que el empleado analizado no presenta una probabilidad significativa de abandonar la empresa. De acuerdo con el modelo SVM seleccionado, su nivel de satisfacción, desempeño y condiciones laborales actuales no lo ubican dentro de un perfil de riesgo.

Este resultado permite concluir que, bajo las condiciones evaluadas, no sería necesario implementar acciones correctivas inmediatas, aunque se recomienda mantener un monitoreo continuo de sus indicadores laborales.

▶ ✎ 📄 ...

Conclusiones finales

En esta práctica se desarrolló un modelo de clasificación utilizando Máquinas de Soporte Vectorial aplicado a una base de datos de Recursos Humanos, con el objetivo de analizar los factores asociados al abandono de empleados dentro de una organización.

Se evaluaron cuatro configuraciones distintas de SVM mediante el uso de kernels lineal, polinomial, radial (RBF) y sigmoide. A partir de métricas cuantitativas, matrices de confusión y reportes de clasificación, se determinó que el modelo con kernel RBF presentó el mejor desempeño predictivo, logrando una mayor precisión y una mejor identificación de empleados en riesgo de abandono.

Finalmente, el modelo seleccionado fue utilizado para generar un pronóstico individual, demostrando su aplicabilidad práctica como herramienta de apoyo a la toma de decisiones estratégicas en el área de Recursos Humanos. Los resultados obtenidos evidencian el valor del uso de modelos de Machine Learning para la prevención de la rotación de personal y la gestión basada en datos.

Práctica: M22 – Clasificación con SVM

Preparación del entorno de trabajo


```
... Python: 3.11.9 (tags/v3.11.9:de54cf5, Apr  2 2024, 10:12:12) [MSC v.1938 64 bit (AMD64)]
Executable: c:\Users\ROBERTSCIENCE\Documents\Tarea M22-CD -RobertScience\.venv\Scripts\python.exe
pandas: 3.0.0
numpy: 2.1.2
```


1

🔍

🔗

⚙️

📦

🧪

🖨️

📱

🔄

👤

⚙️

File Edit Selection View Go Run ...

← →

Tarea M22-CD -RobertScience [Administrator]

🗨️

📏 📐 📑 📔 -

⚙️

Tarea_M22-CD_robertscience.ipynb • Tarea_M22-CD_robertscience.ipynb

notebooks > Tarea_M22-CD_robertscience.ipynb > M22 Tarea M22-CD – Análisis de Clasificación con Máquinas de Soporte Vectorial (SVM) > M22 Conclusiones finales

Generate + Code + Markdown | ▶ Run All ↺ Restart ☒ Clear All Outputs | 📄 Jupyter Variables 📖 Outline ...

Python: 3.11.9 (tags/v3.11.9:de54cf5, Apr 2 2024, 10:12:12) [MSC v.1938 64-bit (AMD64)]

Executable: c:\Users\ROBERTSCIENCE\Documents\Tarea M22-CD -RobertScience\.venv\Scripts\python.exe

pandas: 3.0.0

numpy: 2.4.2

sklearn: 1.8.0

ENTORNO OK

La verificación del entorno confirma que el proyecto se está ejecutando dentro del entorno virtual correspondiente y que las principales librerías necesarias para el análisis de datos y el modelado predictivo se encuentran correctamente instaladas. Con esto, se puede avanzar de forma segura a las siguientes etapas del análisis.

✓ Carga del conjunto de datos

En esta etapa se carga la base de datos `recursos_humanos.csv`, la cual contiene la información histórica de empleados utilizada para el análisis de rotación de personal. La carga del conjunto de datos permite iniciar el proceso de exploración y comprender la estructura general de la información disponible.

A partir de este punto se trabajará con los datos originales, realizando posteriormente las transformaciones necesarias para su uso en modelos de clasificación.

```
# Carga del dataset de recursos humanos
df = pd.read_csv("../data/recursos_humanos.csv")

# Visualización de las primeras observaciones
df.head()
```

[2] ✓ 0.0s

A partir de la inspección general se observa que el conjunto de datos no presenta valores faltantes y que contiene una combinación de variables numéricas y categóricas. Las estadísticas descriptivas permiten identificar rangos y comportamientos generales de las variables, lo cual resulta relevante para las siguientes etapas de preparación de datos.

La variable objetivo del análisis es `left`, la cual indica si un empleado abandonó la empresa (1) o permaneció en ella (0). El análisis de su distribución permite identificar si el conjunto de datos se encuentra equilibrado o desbalanceado entre las clases, lo cual es un aspecto relevante para el desempeño de los modelos de clasificación.

[6]	✓	0.0s
-----	---	------

```
# Distribución porcentual de la variable objetivo
df['left'].value_counts(normalize=True) * 100
```