

Análisis de Clustering con K-Means y PCA

Reflexión y conclusiones del proyecto de análisis de datos

Descripción del proyecto

En este proyecto desarrollé un análisis de agrupamiento utilizando el algoritmo de **K-Means**, una de las técnicas más utilizadas dentro del aprendizaje automático no supervisado. El objetivo principal fue explorar el dataset Iris con la intención de identificar patrones naturales dentro de los datos sin utilizar etiquetas previas durante el proceso de entrenamiento del modelo.

Para lograrlo, primero se realizó un proceso de exploración y comprensión del conjunto de datos. Esto incluyó revisar su estructura, analizar las variables disponibles y observar la distribución de las mediciones presentes en las flores del género Iris. Posteriormente, se prepararon las variables numéricas para poder aplicar correctamente el algoritmo de clustering.

Uno de los puntos más importantes del proyecto fue determinar el número adecuado de clusters. Para ello se utilizaron dos técnicas ampliamente reconocidas en ciencia de datos: el **Método del Codo** y el **Coeficiente Silhouette**. Ambas herramientas permitieron evaluar cómo se comporta el modelo al variar el número de grupos y ayudaron a identificar que el valor óptimo para este dataset es **$k = 3$** .

Este resultado es particularmente interesante porque coincide con el número real de especies presentes en el dataset Iris, lo cual demuestra que el algoritmo es capaz de descubrir estructuras naturales en los datos incluso sin conocer previamente las clases.

Uso de reducción de dimensionalidad (PCA)

Además del clustering tradicional, el proyecto incluyó la aplicación de **PCA (Principal Component Analysis)**, una técnica de reducción de dimensionalidad que permite transformar un conjunto de variables en un número menor de componentes principales conservando la mayor cantidad posible de información.

En este caso, las cuatro variables originales del dataset fueron reducidas a dos componentes principales. Esto permitió representar el dataset en un espacio bidimensional, facilitando la visualización de los clusters generados por el modelo K-Means.

La comparación entre los resultados obtenidos con las variables originales y los datos transformados mediante PCA mostró que la estructura de los clusters se mantiene bastante consistente, lo cual confirma que las características principales del dataset están bien representadas por los componentes principales.

Reflexión final

Desde mi perspectiva, este proyecto representa un ejemplo claro de cómo las técnicas de aprendizaje automático pueden utilizarse para descubrir patrones y estructuras dentro de los datos sin necesidad de etiquetas explícitas.

El algoritmo K-Means permitió identificar agrupamientos naturales basados únicamente en las características numéricas de las flores, mientras que PCA facilitó la interpretación visual del modelo al reducir la dimensionalidad del problema.

Más allá del ejercicio técnico, esta práctica refleja el flujo de trabajo real que se utiliza en muchos proyectos de ciencia de datos: comenzar con la exploración de los datos, comprender su estructura, aplicar modelos analíticos y finalmente interpretar los resultados para generar conocimiento útil.

Este tipo de metodologías es ampliamente utilizado en aplicaciones reales como segmentación de clientes, análisis de comportamiento de usuarios, detección de patrones en grandes volúmenes de datos y descubrimiento de estructuras ocultas en datasets complejos.

Conclusión personal

En conclusión, este proyecto permitió aplicar de forma práctica conceptos clave de aprendizaje automático no supervisado, así como reforzar habilidades fundamentales en análisis de datos, visualización e interpretación de resultados.

Considero que ejercicios como este son fundamentales para comprender cómo los modelos de machine learning pueden transformar datos en información significativa, y cómo estas herramientas pueden utilizarse posteriormente en entornos profesionales para resolver problemas reales dentro de organizaciones y empresas.

Proyecto desarrollado por: RobertScience

<https://robertscience.online/>