

Análisis de Componentes Principales (PCA)

Análisis exploratorio y reducción de dimensionalidad en el dataset Iris

Autor: RobertScience Data Consulting

Proyecto: Práctica M28 – Análisis Multivariado

Herramienta: Python / Jupyter Notebook

Entorno: Visual Studio Code

Descripción del proyecto

El objetivo de este análisis es aplicar la técnica de **Análisis de Componentes Principales (PCA)** al conjunto de datos clásico **Iris Dataset**, con el propósito de reducir la dimensionalidad de las variables y analizar la estructura de agrupamiento existente entre las diferentes especies de flores.

El análisis permitirá identificar qué tan bien los **primeros componentes principales explican la variabilidad total de los datos**, así como visualizar la distribución de las observaciones dentro del nuevo espacio de componentes.

A través de este proceso se busca comprender mejor las relaciones existentes entre las variables del dataset y evaluar si es posible identificar patrones naturales de agrupación entre las diferentes categorías presentes en la base de datos.

Este tipo de análisis es ampliamente utilizado en proyectos de **ciencia de datos, minería de datos y análisis estadístico multivariado**, ya que permite simplificar grandes conjuntos de variables manteniendo la mayor cantidad de información posible.

Importación de librerías

En esta sección se importan las librerías necesarias para el análisis de datos, manipulación de información, visualización gráfica y aplicación del algoritmo de Análisis de Componentes Principales (PCA).

```
In [20]: import pandas as pd
import numpy as np

import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA
```

Carga del conjunto de datos

En esta sección se carga el dataset **Iris**, el cual contiene mediciones de diferentes características físicas de flores pertenecientes a tres especies distintas.

Los datos se obtienen directamente desde una fuente en línea y se almacenan en un DataFrame de Pandas para su posterior análisis.

```
In [21]: url = "https://gist.githubusercontent.com/netj/8836201/raw/iris.csv"

df = pd.read_csv(url)

df.head()
```

```
Out[21]:
```

	sepal.length	sepal.width	petal.length	petal.width	variety
0	5.1	3.5	1.4	0.2	Setosa
1	4.9	3.0	1.4	0.2	Setosa
2	4.7	3.2	1.3	0.2	Setosa
3	4.6	3.1	1.5	0.2	Setosa
4	5.0	3.6	1.4	0.2	Setosa

Exploración inicial de los datos

Antes de aplicar cualquier técnica de análisis es importante comprender la estructura del conjunto de datos.

En esta etapa se revisan aspectos como:

- número de registros
- tipos de variables
- valores faltantes
- estadísticas descriptivas básicas

```
In [22]: df.info()

df.describe()

df['variety'].value_counts()
```

```

<class 'pandas.DataFrame'>
RangeIndex: 150 entries, 0 to 149
Data columns (total 5 columns):
#   Column          Non-Null Count  Dtype
---  -
0   sepal.length    150 non-null   float64
1   sepal.width     150 non-null   float64
2   petal.length    150 non-null   float64
3   petal.width     150 non-null   float64
4   variety         150 non-null   str
dtypes: float64(4), str(1)
memory usage: 6.0 KB

```

```

Out[22]: variety
Setosa      50
Versicolor  50
Virginica   50
Name: count, dtype: int64

```

Selección de variables para el análisis

Para aplicar el Análisis de Componentes Principales (PCA) es necesario trabajar únicamente con variables numéricas.

El dataset Iris contiene cuatro variables cuantitativas que describen características físicas de las flores:

- Longitud del sépalo
- Ancho del sépalo
- Longitud del pétalo
- Ancho del pétalo

Estas variables serán utilizadas para realizar el análisis de reducción de dimensionalidad. La variable correspondiente a la especie se conservará únicamente para fines de interpretación de los resultados.

```

In [23]: X = df.drop('variety', axis=1)

X.head()

```

```

Out[23]:
   sepal.length  sepal.width  petal.length  petal.width
0           5.1           3.5           1.4           0.2
1           4.9           3.0           1.4           0.2
2           4.7           3.2           1.3           0.2
3           4.6           3.1           1.5           0.2
4           5.0           3.6           1.4           0.2

```

Estandarización de las variables

El algoritmo PCA es sensible a la escala de los datos. Por esta razón es necesario estandarizar las variables antes de aplicar el modelo.

Para realizar este proceso se utiliza **StandardScaler**, el cual transforma cada variable para que tenga:

- media igual a 0
- desviación estándar igual a 1

Esto garantiza que todas las variables contribuyan de manera equilibrada al análisis.

```
In [24]: scaler = StandardScaler()

X_scaled = scaler.fit_transform(X)

X_scaled[:5]
```

```
Out[24]: array([[ -0.90068117,  1.01900435, -1.34022653, -1.3154443 ],
 [ -1.14301691, -0.13197948, -1.34022653, -1.3154443 ],
 [ -1.38535265,  0.32841405, -1.39706395, -1.3154443 ],
 [ -1.50652052,  0.09821729, -1.2833891 , -1.3154443 ],
 [ -1.02184904,  1.24920112, -1.34022653, -1.3154443 ]])
```

Matriz de correlación entre variables

Antes de aplicar PCA es útil analizar la relación existente entre las variables del dataset.

La matriz de correlación permite identificar qué variables presentan relaciones lineales fuertes entre sí. Cuando existen correlaciones elevadas, PCA resulta especialmente útil ya que permite reducir la dimensionalidad del conjunto de datos conservando la mayor parte de la información.

```
In [25]: correlation_matrix = df.drop('variety', axis=1).corr()

correlation_matrix
```

```
Out[25]:
```

	sepal.length	sepal.width	petal.length	petal.width
sepal.length	1.000000	-0.117570	0.871754	0.817941
sepal.width	-0.117570	1.000000	-0.428440	-0.366126
petal.length	0.871754	-0.428440	1.000000	0.962865
petal.width	0.817941	-0.366126	0.962865	1.000000

Visualización de la matriz de correlación


Para facilitar la interpretación de las relaciones entre variables se utiliza un **heatmap**, el cual permite visualizar la intensidad de las correlaciones mediante una escala de colores.

Esto permite identificar rápidamente qué variables presentan relaciones más fuertes dentro del conjunto de datos.

```
In [26]: plt.figure(figsize=(8,6))

sns.heatmap(correlation_matrix,
            annot=True,
            cmap='coolwarm')

plt.title("Matriz de correlación - Dataset Iris")
plt.show()
```



Aplicación del Análisis de Componentes Principales

Una vez estandarizadas las variables se procede a aplicar el algoritmo PCA.

El objetivo del PCA es transformar el conjunto original de variables en un nuevo conjunto de variables llamadas **componentes principales**, las cuales son combinaciones lineales de las variables originales.

Estas nuevas variables están ordenadas de acuerdo con la cantidad de varianza que explican dentro del conjunto de datos.

```
In [27]: pca = PCA()

principal_components = pca.fit_transform(X_scaled)
```

Varianza explicada por los componentes principales


Uno de los aspectos más importantes del PCA es analizar cuánta variabilidad de los datos originales es capturada por cada componente principal.

Esto permite determinar cuántos componentes son necesarios para representar adecuadamente la estructura del conjunto de datos.

```
In [28]: explained_variance = pca.explained_variance_ratio_  
  
         explained_variance
```

```
Out[28]: array([0.72962445, 0.22850762, 0.03668922, 0.00517871])
```

```
In [29]: plt.figure(figsize=(8,5))  
  
         plt.bar(  
             range(1, len(explained_variance)+1),  
             explained_variance  
         )  
  
         plt.xlabel("Componentes principales")  
         plt.ylabel("Varianza explicada")  
         plt.title("Scree Plot")  
  
         plt.show()
```



Visualización de la varianza explicada

El siguiente gráfico muestra la proporción de varianza explicada por cada componente principal.


Este tipo de gráfico es útil para identificar cuántos componentes principales son suficientes para representar la mayor parte de la información presente en los datos.

```
In [30]: plt.figure(figsize=(8,5))

plt.plot(range(1, len(explained_variance)+1),
         explained_variance,
         marker='o')

plt.xlabel("Componentes principales")
plt.ylabel("Varianza explicada")
plt.title("Varianza explicada por cada componente")

plt.show()
```



Reducción de dimensionalidad a dos componentes principales

Para facilitar la visualización del análisis se seleccionan únicamente los **dos primeros componentes principales**.

Estos componentes concentran la mayor parte de la variabilidad presente en el conjunto de datos original, permitiendo representar la estructura de los datos en un espacio bidimensional sin perder demasiada información.

```
In [31]: pca = PCA(n_components=2)

principal_components = pca.fit_transform(X_scaled)
```

```
pca_df = pd.DataFrame(
    data=principal_components,
    columns=['PC1', 'PC2']
)

pca_df['variety'] = df['variety']

pca_df.head()
```

```
Out[31]:
```

	PC1	PC2	variety
0	-2.264703	0.480027	Setosa
1	-2.080961	-0.674134	Setosa
2	-2.364229	-0.341908	Setosa
3	-2.299384	-0.597395	Setosa
4	-2.389842	0.646835	Setosa

Varianza explicada por los dos primeros componentes

En esta sección se analiza qué proporción de la varianza total del conjunto de datos es explicada por los dos primeros componentes principales.

Este valor permite evaluar qué tan efectiva es la reducción de dimensionalidad realizada mediante PCA.

```
In [32]: pca.explained_variance_ratio_
```

```
Out[32]: array([0.72962445, 0.22850762])
```

```
In [33]: print("Varianza total explicada por los dos componentes:")
print(pca.explained_variance_ratio_.sum())
```

```
Varianza total explicada por los dos componentes:
0.958132072000016
```

Mapa de observaciones en el espacio de componentes principales

El siguiente gráfico muestra la proyección de cada observación del dataset en el espacio definido por los dos primeros componentes principales.

Cada punto representa una flor del dataset Iris y los colores permiten distinguir las diferentes especies presentes en el conjunto de datos.


Este tipo de visualización permite identificar posibles patrones de agrupación natural dentro de los datos.


```
In [34]: plt.figure(figsize=(8,6))

sns.scatterplot(
    data=pca_df,
    x='PC1',
    y='PC2',
    hue='variety',
    palette='Set1'
)

plt.title("PCA - Proyección de observaciones")
plt.xlabel("Componente Principal 1")
plt.ylabel("Componente Principal 2")

plt.show()
```



Mapa de factores asociados a los componentes principales

El mapa de factores permite visualizar la contribución de cada variable original dentro de los componentes principales.

Cada vector indica la dirección y la magnitud de la influencia de las variables originales sobre los componentes obtenidos mediante PCA.

Esto permite interpretar cuáles variables tienen mayor impacto en la estructura del conjunto de datos.

```
In [35]: loadings = pca.components_.T

features = X.columns

plt.figure(figsize=(8,6))


for i, feature in enumerate(features):
    plt.arrow(0, 0,
              loadings[i,0],
              loadings[i,1],
              head_width=0.05)

    plt.text(loadings[i,0]*1.2,
             loadings[i,1]*1.2,
             feature)

plt.xlabel("PC1")
plt.ylabel("PC2")
plt.title("Mapa de factores - PCA")

plt.grid()

plt.show()
```



Interpretación de los resultados del PCA

Al observar el mapa de observaciones es posible identificar que las diferentes especies de flores tienden a agruparse en regiones específicas dentro del espacio definido por los dos primeros componentes principales.

Esto sugiere que las características medidas en el dataset contienen suficiente información para diferenciar las especies.

El mapa de factores muestra además que ciertas variables, particularmente aquellas relacionadas con las dimensiones del pétalo, tienen una influencia significativa en la separación de los grupos.

En conjunto, estos resultados indican que el PCA logra capturar de manera efectiva la estructura del conjunto de datos utilizando únicamente dos componentes principales.

Conclusión

El análisis de componentes principales permitió reducir la dimensionalidad del dataset Iris manteniendo la mayor parte de la información presente en los datos originales.

Los dos primeros componentes principales explican una proporción muy alta de la varianza total del dataset, lo que permite representar adecuadamente la estructura de los datos en un espacio bidimensional.

Las visualizaciones obtenidas muestran que las diferentes especies de flores presentan patrones de agrupación claramente diferenciados, lo cual confirma que las variables utilizadas contienen información relevante para distinguir entre las distintas categorías.

Este tipo de análisis resulta especialmente útil en proyectos de ciencia de datos, ya que facilita la exploración de conjuntos de datos complejos y permite identificar patrones importantes de manera visual e interpretable.

Varianza explicada acumulada


Para comprender mejor cuánta información se conserva al reducir la dimensionalidad del dataset, se calcula la varianza explicada acumulada.

Este indicador permite observar cuántos componentes principales son necesarios para representar la mayor parte de la variabilidad presente en los datos originales.

```
In [36]: explained_variance = pca.explained_variance_ratio_  
  
cumulative_variance = np.cumsum(explained_variance)  
  
plt.figure(figsize=(8,5))  
  
plt.plot(  
    range(1, len(cumulative_variance)+1),  
    cumulative_variance,  
    marker='o'  
)  
  
plt.xlabel("Número de componentes")  
plt.ylabel("Varianza explicada acumulada")  
plt.title("Varianza explicada acumulada por los componentes principales")
```

```
plt.grid()
```

```
plt.show()
```



Matriz de cargas (Loadings)

Para interpretar correctamente el PCA es importante analizar la contribución de cada variable original a los componentes principales.

Esto permite identificar qué características del dataset tienen mayor influencia en la construcción de cada componente.

```
In [37]: loading_matrix = pd.DataFrame(  
    pca.components_,  
    columns=X.columns,  
    index=['PC1', 'PC2']  
)  
  
loading_matrix
```

```
Out[37]:
```

	sepal.length	sepal.width	petal.length	petal.width
PC1	0.521066	-0.269347	0.580413	0.564857
PC2	0.377418	0.923296	0.024492	0.066942

Contribución de las variables a los componentes

La matriz de contribución permite identificar qué variables originales tienen mayor influencia en cada componente principal.

Valores más altos indican que la variable tiene un peso mayor en la construcción del componente correspondiente.

```
In [38]: contribution = pd.DataFrame(  
    np.abs(pca.components_),  
    columns=X.columns,  
    index=['PC1', 'PC2']  
)  
  
contribution = contribution.T  
  
contribution
```

```
Out[38]:
```

	PC1	PC2
sepal.length	0.521066	0.377418
sepal.width	0.269347	0.923296
petal.length	0.580413	0.024492
petal.width	0.564857	0.066942

Biplot del análisis de componentes principales

El biplot combina la visualización de las observaciones del dataset junto con los vectores que representan las variables originales.

Esta representación permite analizar simultáneamente:

- la distribución de las observaciones
- la influencia de cada variable en los componentes principales

```
In [39]: plt.figure(figsize=(8,6))  
  
sns.scatterplot(  
    x=pca_df['PC1'],  
    y=pca_df['PC2'],  
    hue=pca_df['variety'],  
    palette='Set1'  
)  
  
for i, feature in enumerate(X.columns):  
    plt.arrow(  
        0, 0,  
        loadings[i,0],  
        loadings[i,1],  
        color='black',  
        alpha=0.7,  
        head_width=0.03  
    )  
  
    plt.text(  
        loadings[i,0]*1.2,  
        loadings[i,1]*1.2,  
        feature
```

```


)

plt.xlabel("PC1")
plt.ylabel("PC2")
plt.title("Biplot PCA - Dataset Iris")

plt.grid()

plt.show()

```



Verificación de casos específicos del DataFrame

Para corroborar las conclusiones obtenidas mediante PCA, se revisan algunos registros específicos del DataFrame original.

Esto permite observar si las características de las observaciones coinciden con los patrones identificados en las visualizaciones de los componentes principales.

```
In [40]: df.sample(10)
```

Out[40]:

	sepal.length	sepal.width	petal.length	petal.width	variety
21	5.1	3.7	1.5	0.4	Setosa
37	4.9	3.6	1.4	0.1	Setosa
25	5.0	3.0	1.6	0.2	Setosa
149	5.9	3.0	5.1	1.8	Virginica
85	6.0	3.4	4.5	1.6	Versicolor
73	6.1	2.8	4.7	1.2	Versicolor
49	5.0	3.3	1.4	0.2	Setosa
112	6.8	3.0	5.5	2.1	Virginica
36	5.5	3.5	1.3	0.2	Setosa
147	6.5	3.0	5.2	2.0	Virginica

In [41]: `df[df['variety'] == 'Setosa'].head()`

Out[41]:

	sepal.length	sepal.width	petal.length	petal.width	variety
0	5.1	3.5	1.4	0.2	Setosa
1	4.9	3.0	1.4	0.2	Setosa
2	4.7	3.2	1.3	0.2	Setosa
3	4.6	3.1	1.5	0.2	Setosa
4	5.0	3.6	1.4	0.2	Setosa

Aplicaciones del PCA en ciencia de datos

El Análisis de Componentes Principales es una técnica ampliamente utilizada en proyectos de ciencia de datos y análisis estadístico. Algunas de sus aplicaciones más comunes incluyen:

- reducción de dimensionalidad en datasets con muchas variables
- visualización de datos de alta dimensión
- eliminación de redundancia entre variables altamente correlacionadas
- preparación de datos para algoritmos de machine learning

Gracias a estas propiedades, PCA se ha convertido en una herramienta fundamental dentro del análisis exploratorio de datos y la modelación estadística.

Conclusión final

El análisis de componentes principales permitió identificar patrones relevantes dentro del dataset Iris mediante la reducción de dimensionalidad.

Los dos primeros componentes principales logran explicar una proporción muy alta de la variabilidad del conjunto de datos, lo que permite representar de manera efectiva la estructura de las observaciones en un espacio bidimensional.

Las visualizaciones muestran una clara separación entre algunas especies de flores, particularmente aquellas con características distintivas en las dimensiones de pétalos y sépalos.

El análisis de las contribuciones de las variables indica que las medidas relacionadas con el tamaño de los pétalos tienen una influencia importante en la diferenciación de las especies.

En conjunto, estos resultados confirman que el PCA es una herramienta útil para explorar la estructura de conjuntos de datos multivariados y facilitar la identificación de patrones de agrupación dentro de los datos.

```
In [42]: print("Varianza explicada por cada componente:")
print(pca.explained_variance_ratio_)

print("\nVarianza acumulada:")
print(np.cumsum(pca.explained_variance_ratio_))
```

```
Varianza explicada por cada componente:
[0.72962445 0.22850762]
```

```
Varianza acumulada:
[0.72962445 0.95813207]
```