

Práctica M53 - Intervalos de Confianza y Validación de Supuestos en Regresión Lineal

Evaluación estadística de supuestos y análisis de confianza en modelos predictivos

Mayo 2026

Introducción

En esta práctica desarrollé un análisis estadístico completo utilizando regresión lineal con Python, enfocándome no solo en la construcción del modelo, sino también en la validación de sus supuestos estadísticos y en la interpretación de intervalos de confianza para fortalecer la confiabilidad de las predicciones.

Durante el proceso realicé exploración de datos, análisis descriptivo, entrenamiento del modelo, evaluación de métricas, análisis de residuos y aplicación de pruebas estadísticas complementarias para verificar el comportamiento del modelo desde una perspectiva técnica y analítica.


Descripción de la práctica









Comencé revisando la estructura del dataset, verificando columnas, valores nulos y comportamiento general de las variables. Posteriormente construí un modelo de regresión lineal inicial, evaluando la significancia estadística de sus variables mediante p-values y ajustando el modelo al eliminar variables no relevantes.

Además, validé los supuestos del modelo mediante análisis de residuos, prueba de normalidad Shapiro-Wilk, estadístico Durbin-Watson para independencia y White Test para homocedasticidad. Finalmente generé predicciones con intervalos de confianza para interpretar la incertidumbre asociada a los resultados obtenidos.

Evidencia del desarrollo (Capturas de pantalla)

A continuación presento las capturas del desarrollo completo del proyecto, mostrando paso a paso el análisis realizado desde la preparación de datos hasta la validación final del modelo.





Construcción del modelo de regresión lineal múltiple

Ahora voy a construir el modelo estadístico utilizando Statsmodels para poder analizar:

- coeficientes
- valores p
- pruebas t
- intervalos de confianza
- ajuste del modelo

```
# Agregar constante
X_train_const = sm.add_constant(X_train)

# Crear modelo
model = sm.OLS(y_train, X_train_const).fit()

# Matrices resumen
print(model.summary())
```

Summary Results

	coef	std err	t	P> t	[0.025	0.975]
const	6.1614	0.168	36.608	0.000	5.833	6.490
TV	0.5385	0.002	32.749	0.000	0.536	0.540
Radio	0.2085	0.002	8.000	0.000	0.206	0.210
Newspaper	-0.0015	0.007	-0.203	0.833	-0.016	0.013

Construcción del modelo final

Después de analizar los resultados estadísticos, ahora voy a construir el modelo final utilizando únicamente variables significativas:

```
# Variables finales
X_final = sm.add_constant(X_train[['TV', 'Radio']])

# Crear modelo final
model_final = sm.OLS(y_train, X_final).fit()

print(model_final.summary())
```

Summary Results

	coef	std err	t	P> t	[0.025	0.975]
const	6.1614	0.168	36.608	0.000	5.833	6.490
TV	0.5385	0.002	32.749	0.000	0.536	0.540
Radio	0.2085	0.002	8.000	0.000	0.206	0.210

Selección de variables significativas

Después de generar el modelo inicial, ahora voy a revisar los valores p para identificar cuáles variables son estadísticamente significativas. Las variables con valores p altos podrían eliminarse del modelo final.

```
# Valores p
p_values = model.pvalues
```

Summary Results

	coef	std err	t	P> t	[0.025	0.975]
const	6.1614	0.168	36.608	0.000	5.833	6.490
TV	0.5385	0.002	32.749	0.000	0.536	0.540
Radio	0.2085	0.002	8.000	0.000	0.206	0.210

Construcción del modelo final

Después de analizar los resultados estadísticos, ahora voy a construir el modelo final utilizando únicamente variables significativas:

```
# Variables finales
X_final = sm.add_constant(X_train[['TV', 'Radio']])

# Crear modelo final
model_final = sm.OLS(y_train, X_final).fit()

print(model_final.summary())
```

Summary Results

	coef	std err	t	P> t	[0.025	0.975]
const	6.1614	0.168	36.608	0.000	5.833	6.490
TV	0.5385	0.002	32.749	0.000	0.536	0.540
Radio	0.2085	0.002	8.000	0.000	0.206	0.210

Selección de variables significativas

Después de generar el modelo inicial, ahora voy a revisar los valores p para identificar cuáles variables son estadísticamente significativas. Las variables con valores p altos podrían eliminarse del modelo final.

```
# Valores p
p_values = model.pvalues
```

Summary Results

	coef	std err	t	P> t	[0.025	0.975]
const	6.1614	0.168	36.608	0.000	5.833	6.490
TV	0.5385	0.002	32.749	0.000	0.536	0.540
Radio	0.2085	0.002	8.000	0.000	0.206	0.210

Construcción del modelo final

Después de analizar los resultados estadísticos, ahora voy a construir el modelo final utilizando únicamente variables significativas:

```
# Variables finales
X_final = sm.add_constant(X_train[['TV', 'Radio']])

# Crear modelo final
model_final = sm.OLS(y_train, X_final).fit()

print(model_final.summary())
```

Summary Results

	coef	std err	t	P> t	[0.025	0.975]
const	6.1614	0.168	36.608	0.000	5.833	6.490
TV	0.5385	0.002	32.749	0.000	0.536	0.540
Radio	0.2085	0.002	8.000	0.000	0.206	0.210

Evaluación del ajuste del modelo

Ahora voy a evaluar qué tan bueno es el ajuste del modelo utilizando el coeficiente de determinación R².

```
# Datos de prueba
X_test_const = sm.add_constant(X_test)

# Predicciones
predicciones = model.predict(X_test_const)
```

Summary Results

	coef	std err	t	P> t	[0.025	0.975]
const	6.1614	0.168	36.608	0.000	5.833	6.490
TV	0.5385	0.002	32.749	0.000	0.536	0.540
Radio	0.2085	0.002	8.000	0.000	0.206	0.210

Justificación de variables utilizadas en la predicción

Aunque la consigna proporciona valores para TV, Radio y Newspaper, el modelo final únicamente considera las variables TV y Radio debido a que Newspaper no presenta significancia estadística dentro del modelo de regresión lineal múltiple. Por esta razón, la predicción y el intervalo de confianza serán calculados utilizando únicamente las variables significativas del modelo final.

- TV = 100
- Radio = 50

Intervalo de confianza del 90%

Con base en el modelo final reducido, ahora voy a calcular un intervalo de confianza del 90% utilizando únicamente las variables significativas conservadas en la ecuación.

- TV = 100
- Radio = 50

```
# Datos de prueba
X_test_const = sm.add_constant(X_test)

# Predicciones
predicciones = model.predict(X_test_const)
```

Summary Results

	coef	std err	t	P> t	[0.025	0.975]
const	6.1614	0.168	36.608	0.000	5.833	6.490
TV	0.5385	0.002	32.749	0.000	0.536	0.540
Radio	0.2085	0.002	8.000	0.000	0.206	0.210

Análisis de residuos

Summary Results

	coef	std err	t	P> t	[0.025	0.975]
const	6.1614	0.168	36.608	0.000	5.833	6.490
TV	0.5385	0.002	32.749	0.000	0.536	0.540
Radio	0.2085	0.002	8.000	0.000	0.206	0.210

Análisis de residuos

Ahora voy a analizar los residuos del modelo para validar algunos supuestos estadísticos importantes.

```
# Residuos
residuos = final_model.resid

# Histograma
plt.figure(figsize=(8,5))
plt.hist(residuos)
plt.title('Distribución de residuos')
plt.show()
```

Summary Results

	coef	std err	t	P> t	[0.025	0.975]
const	6.1614	0.168	36.608	0.000	5.833	6.490
TV	0.5385	0.002	32.749	0.000	0.536	0.540
Radio	0.2085	0.002	8.000	0.000	0.206	0.210

Distribución de residuos

Summary Results

	coef	std err	t	P> t	[0.025	0.975]
const	6.1614	0.168	36.608	0.000	5.833	6.490
TV	0.5385	0.002	32.749	0.000	0.536	0.540
Radio	0.2085	0.002	8.000	0.000	0.206	0.210

Análisis de residuos

Summary Results

	coef	std err	t	P> t	[0.025	0.975]
const	6.1614	0.168	36.608	0.000	5.833	6.490
TV	0.5385	0.002	32.749	0.000	0.536	0.540
Radio	0.2085	0.002	8.000	0.000	0.206	0.210

Validación de normalidad

Ahora voy a validar el supuesto de normalidad utilizando la prueba de Shapiro-Wilk.











```
# Shapiro-Wilk
shapiro_test = shapiro(residuos)





print('Estadístico:', shapiro_test.statistic)
print('Valor p:', shapiro_test.pvalue)
```

Interpretación de normalidad

Summary Results

	coef	std err	t	P> t	[0.025	0.975]
const	6.1614	0.168	36.608	0.000	5.833	6.490
TV	0.5385	0.002	32.749	0.000	0.536	0.540
Radio	0.2085	0.002	8.000	0.000	0.206	0.210





Conclusión técnica

Después de desarrollar el modelo y validar sus supuestos estadísticos, observé que no basta con obtener un buen ajuste predictivo; también es indispensable comprobar que el modelo cumple condiciones estadísticas que respalden la validez de sus resultados. El análisis de residuos, pruebas de normalidad, independencia y homocedasticidad permitieron complementar la evaluación técnica del modelo.

Lo que aprendí en esta práctica

Durante esta práctica reforcé conocimientos sobre intervalos de confianza, validación de supuestos en regresión lineal, análisis de residuos y aplicación de pruebas estadísticas complementarias. También comprendí mejor cómo interpretar la confiabilidad de un modelo más allá de métricas predictivas, integrando análisis estadístico para respaldar conclusiones dentro de un proyecto de Ciencia de Datos.