

RobertScience Data Analytics

Reporte Técnico de Proyecto

Consolidación y Preparación de Datos de Ventas

Autor: RobertScience

1. Descripción General del Proyecto

Desarrollé este proyecto con el objetivo de establecer una primera etapa de integración y preparación de información comercial utilizando Python como herramienta principal de procesamiento. Durante esta fase trabajé con diferentes fuentes estructuradas de datos, incluyendo tablas dimensionales y una tabla principal de hechos de ventas, con la finalidad de construir una base organizada para futuros procesos de análisis, transformación y generación de información estratégica.

El enfoque principal estuvo centrado en la correcta carga de información, exploración inicial de estructuras y validación básica de calidad, estableciendo una metodología ordenada para trabajar posteriormente con procesos ETL más avanzados.

2. Fuentes de Información Analizadas

Para el desarrollo utilicé un modelo basado en información comercial compuesto por cinco fuentes principales:

- DIM_CALENDAR: información relacionada con fechas y periodos de análisis.
- DIM_CATEGORY: clasificación de categorías comerciales.
- DIM_PRODUCT: catálogo y características principales de productos.
- DIM_SEGMENT: información utilizada para segmentación comercial.
- FACT_SALES: tabla principal con registros de ventas.

Los archivos originales fueron utilizados como fuentes de trabajo, pero no forman parte del repositorio público debido a su tamaño y para mantener buenas prácticas de control de versiones.

3. Proceso Técnico Implementado

Carga de Información

Desarrollé un proceso automatizado mediante Python y Pandas para importar cada fuente considerando su formato correspondiente, diferenciando entre archivos CSV y Excel.

Exploración Inicial

Realicé una revisión estructural de cada dataset para identificar cantidad de registros, número de columnas, nombres de variables, tipos de datos y primeros registros disponibles.

Validación de Calidad

Implementé validaciones iniciales enfocadas en la detección de valores faltantes mediante análisis de datos nulos, permitiendo conocer el estado de cada fuente antes de aplicar transformaciones posteriores.

4. Arquitectura del Proyecto

Organicé el desarrollo utilizando una estructura separada entre código, documentación y datos. Esta distribución permite mantener un flujo profesional donde cada componente cumple una función específica dentro del proyecto.

- Python: automatización del proceso de carga y validación.
- Notebook: documentación reproducible del análisis.
- Data Raw: referencia de fuentes originales.
- Data Processed: espacio destinado a información transformada.
- Docs: documentación técnica del proyecto.

5. Herramientas Utilizadas

- Python 3.11
- Pandas
- NumPy
- Jupyter Notebook
- Visual Studio Code
- OpenPyXL

6. Resultados Obtenidos

Como resultado de esta primera etapa logré establecer un flujo funcional para la incorporación y revisión inicial de información comercial. El proyecto cuenta con:

- Carga automatizada de múltiples fuentes.
- Exploración estructural inicial.
- Validación básica de calidad.
- Organización profesional del repositorio.
- Base preparada para procesos ETL posteriores.

7. Próximas Etapas

Este desarrollo puede evolucionar mediante procesos adicionales de limpieza, normalización, integración dimensional, generación de indicadores comerciales, visualización mediante dashboards y construcción de modelos analíticos.

RobertScience

Data Analytics & Engineering Solutions

<https://robertscience.online>