

Práctica Entregable 6 - Forecasting de Ventas con Series Temporales

Modelo predictivo de ventas (Vanish y Lysol) usando ARIMA

Mayo 2026

Introducción

En esta práctica yo desarrollé un modelo de forecasting de ventas utilizando series temporales con ARIMA. Mi objetivo fue predecir el comportamiento futuro de ventas de productos como Vanish y Lysol a partir de datos históricos consolidados.

Yo integré múltiples fuentes de datos, realicé la limpieza de llaves, construí el dataset unificado y posteriormente analicé el comportamiento temporal de las ventas.

Desarrollo del proyecto

Yo cargué los datos provenientes de tablas dimensionales y la tabla de hechos, luego realicé la limpieza y normalización de identificadores para poder unir correctamente la información.

Posteriormente yo construí la serie temporal de ventas y entrené un modelo ARIMA para realizar el forecasting.

Yo dividí los datos en entrenamiento y prueba usando una división temporal para validar correctamente el comportamiento del modelo.


Evaluación del modelo




Yo evalué el modelo utilizando métricas como MAE, RMSE y MAPE. También analicé los criterios AIC y BIC para validar la calidad del ajuste.

Los resultados mostraron que el modelo tiene un buen nivel de precisión con un MAPE inferior al 10%, lo que indica un desempeño sólido para forecasting.

Evidencia del desarrollo

A continuación presento las capturas de todo el proceso que yo realicé, desde la carga de datos hasta la generación del modelo predictivo.





Construcción del modelo predictivo (ARIMA)

Para crear el modelo se requiere definir los parámetros de los componentes AR, I y MA. En este caso se utilizará un modelo ARIMA(1,1,1).

```
from statsmodels.tsa.arima.model import ARIMA  
model = ARIMA(df['TOTAL_VALUE_SALES'], order=(1,1,1))  
model_fit = model.fit()
```

Construcción del modelo predictivo (ARIMA)

Dado que el objetivo es predecir ventas futuras a partir de su comportamiento histórico en el tiempo, se seleccionó un modelo ARIMA (Autoregressive Integrated Moving Average). Este modelo es adecuado porque permite capturar patrones, tendencias y dependencia entre observaciones consecutivas.

```
from statsmodels.tsa.arima.model import ARIMA  
model = ARIMA(df['TOTAL_VALUE_SALES'], order=(1,1,1))  
model_fit = model.fit()
```

Construcción del modelo predictivo (ARIMA)

Modelo ARIMA simple

```
model = ARIMA(df['TOTAL_VALUE_SALES'], order=(1,1,1))  
model_fit = model.fit()  
print(model_fit.summary())
```

OBSERVACIONES	
Dep. Variable:	TOTAL_VALUE_SALES
Model:	ARIMA(1,1,1)
Date:	Fri, 22 May 2020
Sample:	0 to 49
Log Likelihood:	-1194.618
AIC:	2394.236
BIC:	2400.140
Constrains:	0

	coef	std err	z	P> z	[0.025	0.975]
ar.L1	0.2402	0.096	2.513	0.012	0.048	0.432
ma.L1	-0.7003	0.100	-7.000	0.000	-0.900	-0.500
sigma2	6.47e+06	1.13e+05	5.724	0.000	5.27e+06	8.07e+06

Log-likelihood (ll): -1194.618

Log-likelihood (ll): -1194.618

Log-likelihood (ll): -1194.618

Construcción del modelo predictivo (ARIMA)

Modelo ARIMA simple

```
model = ARIMA(df['TOTAL_VALUE_SALES'], order=(1,1,1))  
model_fit = model.fit()  
print(model_fit.summary())
```

	coef	std err	z	P> z	[0.025	0.975]
ar.L1	0.2402	0.096	2.513	0.012	0.048	0.432
ma.L1	-0.7003	0.100	-7.000	0.000	-0.900	-0.500
sigma2	6.47e+06	1.13e+05	5.724	0.000	5.27e+06	8.07e+06

Log-likelihood (ll): -1194.618

Log-likelihood (ll): -1194.618

Log-likelihood (ll): -1194.618

Evaluación mediante AIC y BIC

Se evaluó el modelo mediante los criterios AIC (Akaike Information Criterion) y BIC (Bayesian Information Criterion), los cuales permiten medir la calidad del ajuste considerando tanto el desempeño como la complejidad del modelo.

Valores menores en estos criterios suelen indicar un mejor equilibrio entre precisión y simplicidad. Los resultados obtenidos muestran que el modelo ARIMA seleccionado presenta un ajuste adecuado para el análisis y forecasting de ventas.

```
print(model_fit.summary())
```

Construcción del modelo predictivo (ARIMA)

Modelo ARIMA simple

```
model = ARIMA(df['TOTAL_VALUE_SALES'], order=(1,1,1))  
model_fit = model.fit()  
print(model_fit.summary())
```

	coef	std err	z	P> z	[0.025	0.975]
ar.L1	0.2402	0.096	2.513	0.012	0.048	0.432
ma.L1	-0.7003	0.100	-7.000	0.000	-0.900	-0.500
sigma2	6.47e+06	1.13e+05	5.724	0.000	5.27e+06	8.07e+06

Log-likelihood (ll): -1194.618

Log-likelihood (ll): -1194.618

Log-likelihood (ll): -1194.618

Construcción del modelo predictivo (ARIMA)

Modelo ARIMA simple



```
model = ARIMA(df['TOTAL_VALUE_SALES'], order=(1,1,1))  
model_fit = model.fit()  
print(model_fit.summary())
```

	coef	std err	z	P> z	[0.025	0.975]
ar.L1	0.2402	0.096	2.513	0.012	0.048	0.432
ma.L1	-0.7003	0.100	-7.000	0.000	-0.900	-0.500
sigma2	6.47e+06	1.13e+05	5.724	0.000	5.27e+06	8.07e+06

Log-likelihood (ll): -1194.618

Log-likelihood (ll): -1194.618

Log-likelihood (ll): -1194.618



Construcción del modelo predictivo (ARIMA)

Modelo ARIMA simple

```
model = ARIMA(df['TOTAL_VALUE_SALES'], order=(1,1,1))  
model_fit = model.fit()  
print(model_fit.summary())
```

	coef	std err	z	P> z	[0.025	0.975]
ar.L1	0.2402	0.096	2.513	0.012	0.048	0.432
ma.L1	-0.7003	0.100	-7.000	0.000	-0.900	-0.500
sigma2	6.47e+06	1.13e+05	5.724	0.000	5.27e+06	8.07e+06

Log-likelihood (ll): -1194.618

Log-likelihood (ll): -1194.618

Log-likelihood (ll): -1194.618

Interpretación de resultados

El modelo ARIMA construido permite generar predicciones de ventas futuras utilizando el comportamiento histórico observado de las ventas. Los resultados obtenidos muestran que el modelo ARIMA seleccionado presenta un ajuste adecuado para el análisis y forecasting de ventas.

Los valores obtenidos fueron:

- MAE: 2053.30
- RMSE: 4040.61
- MAPE: 6.03%

Un MAPE inferior al 10% indica que el modelo presenta un buen nivel de precisión predictiva para este caso de estudio.

Con base en el forecasting generado, se observa una tendencia relativamente estable en las ventas futuras, lo que permite utilizar este modelo como herramienta de apoyo para la planeación comercial y análisis de demanda.

Conclusión

Yo considero que el modelo ARIMA implementado me permitió generar predicciones confiables de ventas futuras. El proceso de análisis, limpieza de datos y modelado temporal me permitió capturar correctamente los patrones históricos.

Este tipo de modelos puede ser utilizado como apoyo directo en la toma de decisiones comerciales y planificación de demanda.