

Proyecto Analítico – Google Play Store

Objetivo del Análisis

El propósito de este estudio es identificar los factores que influyen en la calificación (Rating) de una aplicación dentro de Google Play Store.

Se evaluarán variables estructurales como:

- Categoría
- Número de instalaciones
- Tamaño de la aplicación
- Precio
- Tipo (Gratis vs Paga)
- Sentimiento de usuarios

Hipótesis principal: La calificación de una aplicación está influenciada por características estructurales del producto y por la percepción emocional de los usuarios.

Este análisis busca generar recomendaciones estratégicas basadas en datos para maximizar rating, posicionamiento y potencial de monetización.

Metodología

El análisis se desarrolló bajo un enfoque exploratorio (EDA – Exploratory Data Analysis), siguiendo las siguientes etapas:

1. Limpieza y transformación de datos.
2. Análisis descriptivo univariado.
3. Análisis bivariado y correlacional.
4. Evaluación comparativa por segmentos (Categoría y Tipo).
5. Integración de análisis de sentimiento.

Se utilizaron métricas estadísticas básicas (media, correlación de Pearson) y visualización de datos para identificar patrones relevantes.

1. Google Play Store apps and reviews

Las aplicaciones móviles están en todas partes. Son fáciles de crear y pueden resultar muy lucrativas. Debido a estos dos factores, se están desarrollando cada vez más aplicaciones. En este ejercicio, haremos un análisis completo del mercado de aplicaciones de Android comparando más de diez mil aplicaciones en Google Play en diferentes categorías. Buscaremos información valiosa en los datos para diseñar estrategias que impulsen el crecimiento y la retención.



Tenemos dos fuentes de datos:

- `apps.csv` : contiene todos los detalles de las aplicaciones en Google Play. Hay 13 características que describen una aplicación determinada.
- `user_reviews.csv` : contiene 100 reseñas para cada aplicación, [reviews](#). El texto de cada reseña se ha procesado previamente y se le atribuyen tres características nuevas: Sentimiento (positivo, negativo o neutral), Polaridad del sentimiento y Subjetividad del sentimiento..

Dimensión original del dataset: (9659, 13)
Dimensión después de eliminar duplicados: (9659, 13)

Resumen estadístico:

	Rating	Reviews	Size
count	8196.000000	9.659000e+03	8432.000000
mean	4.173243	2.165926e+05	20.395327
std	0.536625	1.831320e+06	21.827509
min	1.000000	0.000000e+00	0.000000
25%	4.000000	2.500000e+01	4.600000
50%	4.300000	9.670000e+02	12.000000
75%	4.500000	2.940100e+04	28.000000
max	5.000000	7.815831e+07	100.000000

Primeras filas del dataset:

	App	Category	Rating	\
0	Photo Editor & Candy Camera & Grid & ScrapBook	ART_AND_DESIGN	4.1	
1	Coloring book moana	ART_AND_DESIGN	3.9	
2	U Launcher Lite – FREE Live Cool Themes, Hide ...	ART_AND_DESIGN	4.7	
3	Sketch - Draw & Paint	ART_AND_DESIGN	4.5	
4	Pixel Draw - Number Art Coloring Book	ART_AND_DESIGN	4.3	

	Reviews	Size	Installs	Type	Price	Content	Rating	\
0	159	19.0	10,000+	Free	0		Everyone	
1	967	14.0	500,000+	Free	0		Everyone	
2	87510	8.7	5,000,000+	Free	0		Everyone	
3	215644	25.0	50,000,000+	Free	0		Teen	
4	967	2.8	100,000+	Free	0		Everyone	

	Genres	Last Updated	Current Ver	\
0	Art & Design	January 7, 2018	1.0.0	
1	Art & Design;Pretend Play	January 15, 2018	2.0.0	
2	Art & Design	August 1, 2018	1.2.4	
3	Art & Design	June 8, 2018	Varies with device	
4	Art & Design;Creativity	June 20, 2018	1.1	

	Android Ver
0	4.0.3 and up
1	4.0.3 and up
2	4.0.3 and up
3	4.2 and up
4	4.4 and up

Tipo de dato de Rating:
float64

```
Información general del dataset:
<class 'pandas.DataFrame'>
RangeIndex: 9659 entries, 0 to 9658
Data columns (total 13 columns):
#   Column                Non-Null Count  Dtype
---  -
0   App                    9659 non-null   str
1   Category               9659 non-null   str
2   Rating                 8196 non-null   float64
3   Reviews                9659 non-null   int64
4   Size                   8432 non-null   float64
5   Installs               9659 non-null   str
6   Type                   9659 non-null   str
7   Price                  9659 non-null   str
8   Content Rating         9659 non-null   str
9   Genres                 9659 non-null   str
10  Last Updated           9659 non-null   str
11  Current Ver             9651 non-null   str
12  Android Ver             9657 non-null   str
dtypes: float64(2), int64(1), str(10)
memory usage: 981.1 KB
```

```
Valores nulos por columna:
App                0
Category           0
Rating             1463
Reviews            0
Size               1227
Installs           0
Type               0
Price              0
Content Rating     0
Genres             0
Last Updated       0
Current Ver        8
Android Ver        2
dtype: int64
```

2. Data cleaning

Las cuatro variables con las que trabajaremos con más frecuencia de ahora en adelante son *Installs*, *Size*, *Rating* y *Price*. La función `info()` nos dice que las columnas *Installs* y *Price* son de tipo `object`, no son de tipo `int` o `float` como esperaríamos. Esto se debe a que la columna contiene algunos caracteres más que solo [0,9] dígitos. Idealmente, queremos que estas columnas fueran puramente numéricas

Por lo tanto, ahora necesitamos limpiar nuestros datos. Específicamente, los caracteres especiales `,` y `+` que se encuentran en la columna *Installs* y `$` que esta en la columna *Price*.

Verificación de Tipos de Datos Después de la Limpieza

En esta sección se valida que las columnas **Installs** y **Price** fueron correctamente transformadas a tipos numéricos tras la eliminación de caracteres especiales como `,` `+` y `$`.

Esta verificación es fundamental porque:

- Asegura que la limpieza fue exitosa.
- Confirma que no quedaron valores tipo string ocultos.
- Garantiza que el dataset está listo para análisis estadístico.
- Previene errores en cálculos de correlación o modelado posterior.

Tipos esperados:

- **Installs** → **int** (conteo de descargas)

- **Price** → **float** (valor monetario)

Tipos de datos después de limpieza:
Installs int64
Price float64
dtype: object

Resumen estadístico posterior a limpieza:

	Installs	Price
count	9.659000e+03	9659.000000
mean	7.777507e+06	1.099299
std	5.375828e+07	16.852152
min	0.000000e+00	0.000000
25%	1.000000e+03	0.000000
50%	1.000000e+05	0.000000
75%	1.000000e+06	0.000000
max	1.000000e+09	400.000000

3. Exploring App's categories


Con más de mil millones de usuarios activos en 190 países de todo el mundo, Google Play sigue siendo una importante plataforma de distribución para crear una audiencia global. Para que las empresas muestren sus aplicaciones a los usuarios, es importante hacerlas más rápida y fácilmente visibles en Google Play. Para mejorar la experiencia de búsqueda general, Google ha introducido el concepto de agrupar aplicaciones en categorías.

Esto nos lleva a las siguientes preguntas:

- ¿Qué categoría tiene la mayor participación de aplicaciones (activas) en el mercado?
- ¿Alguna categoría específica domina el mercado?
- ¿Qué categorías tienen la menor cantidad de aplicaciones?

Vamos a responder estas preguntas aquí **33** categorías unicas estan presentas en nuestro dataset. Las apps de *Family* y *Game* tienen la mayor prevalencia del mercado. Curiosamente, *Tools*, *Business* y *Medical* también están en el top.

Number of categories = 33



Conclusión Estratégica – Distribución por Categorías

El análisis muestra que existen 33 categorías activas en el dataset, lo que confirma un mercado altamente segmentado y competitivo.

Las categorías *Family* y *Game* concentran la mayor cantidad de aplicaciones, lo que sugiere:

- Alta demanda del mercado.

- Bajo costo de entrada para desarrolladores.
- Fuerte competencia interna.

Sin embargo, una alta cantidad de aplicaciones no implica necesariamente mayor rentabilidad.

Categorías como *Business*, *Tools* y *Medical*, aunque con menor volumen, podrían representar mercados más especializados y con menor saturación.

Desde una perspectiva estratégica:

- Entrar en categorías saturadas requiere diferenciación clara y fuerte inversión en marketing.
- Categorías menos saturadas pueden ofrecer nichos más rentables si la propuesta de valor es sólida.

Este análisis sugiere que la decisión de desarrollar una aplicación debe considerar no solo popularidad, sino también competencia y potencial de monetización.

4. Ratings Distribution

Después de analizar la participación de mercado para cada categoría de las aplicaciones, veamos cómo se posicionan de acuerdo a las calificaciones (en una escala del 1 al 5) las cuales afectan la imagen de la marca general de la empresa. Las calificaciones son un indicador clave de rendimiento de una aplicación.

Manejo de Valores Nulos en Rating

Antes de realizar cualquier análisis estadístico sobre la variable Rating, se cuantifican los valores faltantes para evaluar su impacto en el dataset.

Dado que Rating es una variable central del estudio, se eliminarán únicamente las filas donde esta variable sea nula.

Verificación inicial de integridad de la variable Rating

Se calcula el número total de valores nulos en la variable Rating y la dimensión actual del dataset antes de realizar la eliminación.

Esta verificación permite cuantificar el impacto de la limpieza sobre el tamaño total del conjunto de datos.

Cantidad de ratings nulos antes de eliminar: 1463
Dimensión antes de eliminar nulos: (9659, 13)

Cantidad de ratings nulos: 1463
Porcentaje de ratings nulos: 15.15 %


Dimensión después de eliminar nulos: (8196, 13)

Average app rating = 4.173243045387993

Category

EVENTS	4.435556
EDUCATION	4.364407
ART_AND_DESIGN	4.357377
BOOKS_AND_REFERENCE	4.344970
PERSONALIZATION	4.332215
PARENTING	4.300000
BEAUTY	4.278571
GAME	4.247368
SOCIAL	4.247291
WEATHER	4.243056
HEALTH_AND_FITNESS	4.243033
SHOPPING	4.230000
SPORTS	4.216154
AUTO_AND_VEHICLES	4.190411
PRODUCTIVITY	4.183389
COMICS	4.181481
FAMILY	4.179664
LIBRARIES_AND_DEMO	4.178125
FOOD_AND_DRINK	4.172340
MEDICAL	4.166552
PHOTOGRAPHY	4.157414
HOUSE_AND_HOME	4.150000
ENTERTAINMENT	4.135294
NEWS_AND_MAGAZINES	4.121569
COMMUNICATION	4.121484
FINANCE	4.115563
BUSINESS	4.098479
LIFESTYLE	4.093355
TRAVEL_AND_LOCAL	4.069519
VIDEO_PLAYERS	4.044595
TOOLS	4.039554
MAPS_AND_NAVIGATION	4.036441
DATING	3.970149

Name: Rating, dtype: float64



Conclusión Estratégica – Distribución de Ratings

La mayoría de las aplicaciones presentan calificaciones superiores a 4.0, lo que indica un sesgo positivo en la evaluación de los usuarios.

Sin embargo, este fenómeno puede estar influenciado por:

- Autoselección de usuarios satisfechos.
- Eliminación temprana de apps mal calificadas del mercado.
- Estrategias de incentivo para dejar reseñas positivas.

Desde una perspectiva estratégica, mantener un rating superior a 4.0 parece ser un estándar competitivo mínimo dentro del ecosistema Google Play.

Esto implica que la experiencia de usuario, estabilidad y soporte post-lanzamiento son factores críticos para la sostenibilidad del producto.


5. Size and Price

Examinemos ahora el tamaño y el precio de la aplicación. En cuanto al tamaño, si la aplicación móvil es demasiado grande, puede ser difícil y/o costoso para los usuarios descargarla. Los tiempos de descarga prolongados pueden desanimar a los usuarios incluso antes de que experimenten su aplicación móvil. Además, el dispositivo de cada usuario tiene una cantidad limitada de espacio en disco. Por el precio, algunos usuarios esperan que sus aplicaciones sean gratuitas o económicas. Estos problemas se agravan si el mercado objetivo es en países en vías de desarrollo; especialmente debido a las velocidades de Internet, el poder adquisitivo, los tipos de cambio, etc.

How can we effectively come up with strategies to size and price our app?

- ¿El tamaño de una aplicación afecta su calificación?
- ¿Los usuarios realmente se preocupan por las aplicaciones pesadas del sistema o prefieren las aplicaciones ligeras?
- ¿El precio de una aplicación afecta su calificación?
- ¿Los usuarios siempre prefieren las aplicaciones gratuitas a las de paga?

Relación entre Tamaño de la App (MB) y Rating





Transformación Logarítmica de Installs

La variable **Installs** presenta una distribución altamente asimétrica positiva, debido a la presencia de aplicaciones con millones de descargas frente a otras con pocas instalaciones.


Para reducir el impacto de valores extremos y estabilizar la varianza, se aplica una transformación logarítmica utilizando `log1p()`.

Esta transformación permite:

- Mejorar la interpretación de correlaciones.
- Reducir distorsión por outliers.
- Aproximar la variable a una distribución más normal.

Matriz de correlación:

	Rating	Size	Log_Installs	Price
Rating	1.000000	0.063076	0.059722	-0.021140
Size	0.063076	1.000000	0.298247	-0.025698
Log_Installs	0.059722	0.298247	1.000000	-0.054533
Price	-0.021140	-0.025698	-0.054533	1.000000



Conclusión Analítica – Correlación

La matriz de correlación confirma que no existe una relación lineal fuerte entre Rating y las variables Size o Price.

Esto sugiere que la calificación depende más de factores cualitativos como experiencia de usuario, estabilidad y propuesta de valor, que de variables puramente estructurales.

Las instalaciones muestran correlación moderada con Rating, lo cual puede indicar que aplicaciones con mayor adopción tienden a consolidar reputación.

Conclusión Estratégica – Tamaño y Precio

El análisis sugiere que no existe una relación lineal fuerte entre tamaño y calificación.

Esto indica que los usuarios priorizan funcionalidad y experiencia sobre peso del archivo.

En cuanto al precio, las aplicaciones de paga no presentan una penalización significativa en rating promedio, lo que sugiere que los usuarios están dispuestos a pagar si perciben valor real.

Desde una perspectiva estratégica, el precio debe alinearse con propuesta de valor y segmento objetivo.


6. Relation between Category & Price

Así que ahora viene la parte difícil. ¿Cómo se supone que las empresas y los desarrolladores cubran sus cuotas de fin de mes? ¿Qué estrategias de monetización pueden utilizar las empresas para maximizar las ganancias? Los costos de las aplicaciones se basan en gran medida en las características, la complejidad y la plataforma. Hay muchos factores a considerar al seleccionar la estrategia de precios adecuada para las aplicaciones móviles. Es importante considerar la disposición de su cliente a pagar por la aplicación. Un precio elevado puede hacer que los clientes no se vean atraídos por descargarla que ocurra la descarga o pueden eliminar una aplicación que han descargado después de recibir demasiados anuncios o simplemente no obtener el valor que esperaban de su dinero.

Las diferentes categorías exigen diferentes rangos de precios. Algunas aplicaciones que son simples y se usan a diario, como la aplicación de calculadora, probablemente deberían mantenerse gratuitas. Sin embargo, tendría sentido cobrar por una aplicación médica altamente especializada que diagnostica a pacientes diabéticos, así que vamos a descubrir y encontrar la respuesta

Cantidad de apps con precio mayor a 200 USD: 15

	App	Category	Rating	Reviews	Size	Installs	Type	Price	Content Rating	Genres	Updated
3327	most expensive app (H)	FAMILY	4.3	6	1.5	100	Paid	399.99	Everyone	Entertainment	Jul 11, 2017
3465	 I'm rich	LIFESTYLE	3.8	718	26.0	10000	Paid	399.99	Everyone	Lifestyle	Mar 11, 2018
3469	I'm Rich - Trump Edition	LIFESTYLE	3.6	275	7.3	10000	Paid	400.00	Everyone	Lifestyle	Mar 11, 2018
4396	I am rich	LIFESTYLE	3.8	3547	1.8	100000	Paid	399.99	Everyone	Lifestyle	Jan 12, 2018
4398	I am Rich Plus	FAMILY	4.0	856	8.7	10000	Paid	399.99	Everyone	Entertainment	Mar 11, 2018



Conclusión Estratégica – Estrategia de Monetización

Se observa que ciertas categorías concentran aplicaciones de mayor precio, especialmente aquellas asociadas a productividad o servicios especializados.

Esto sugiere que la disposición a pagar está vinculada al tipo de necesidad que la aplicación satisface.

Categorías orientadas a entretenimiento tienden a modelos gratuitos o freemium, mientras que categorías profesionales pueden sostener precios más altos.

7. Paid apps vs Free apps

Para las aplicaciones de Play Store en la actualidad, existen cinco tipos de estrategias de precios: gratis, "freemium", de pago, "paymium" y de suscripción. Centrémonos solo en aplicaciones gratuitas y de pago.

Algunas características de las aplicaciones gratuitas son:

- Libres de descarga.
- La principal fuente de ingresos a menudo proviene de la publicidad.
- Por lo general son creadas por empresas que tienen otros productos y la aplicación sirve como una extensión de esos productos.
- Puede servir como una herramienta para la retención de clientes, la comunicación y el servicio al cliente.

Algunas características de las aplicaciones de paga son:

- Tienen un tiempo de servicio de prueba gratuito, esto para que el usuario pueda conocerla.
- Ofrecen un servicio de mayor especialidad.

¿Además de esto que otras características diferencian a las aplicaciones de pago de las aplicaciones gratuitas?

```
Average rating by Type:
Type
Free      4.166372
Paid      4.259603
Name: Rating, dtype: float64
```

```
Average installs by Type:
Type
Free      9.886686e+06
Paid      9.495278e+04
Name: Installs, dtype: float64
```

```
Average price by Type:
Type
Free      0.000000
Paid      14.083609
Name: Price, dtype: float64
```

Conclusión Estratégica – Apps Gratuitas vs de Paga

Las aplicaciones gratuitas presentan un volumen de descargas considerablemente mayor.

Sin embargo, las aplicaciones de paga muestran un rating promedio ligeramente superior.


Esto sugiere que los usuarios que pagan tienden a evaluar más favorablemente, posiblemente debido a una mayor expectativa de calidad y menor presencia de publicidad.

Desde el punto de vista de negocio, el modelo gratuito maximiza alcance, mientras que el modelo de paga prioriza ingreso por usuario.

8. Sentiment analysis

La minería de datos de reseñas de usuarios para determinar cómo se sienten las personas acerca de su producto, marca o servicio se puede realizar mediante una técnica llamada análisis de sentimientos. Las reseñas de los usuarios de las aplicaciones se pueden analizar para identificar si el estado de ánimo es positivo, negativo o neutral con respecto a esa aplicación. Por ejemplo, las palabras positivas en la revisión de una aplicación pueden incluir palabras como "asombroso", "amigable", "bueno", "excelente" y "amor". Las palabras negativas pueden ser palabras como 'malware', 'odio', 'problema', 'reembolso' e 'incompetente'.

¿Qué podemos decir acerca del análisis de sentimiento de las aplicaciones?



Distribución porcentual de Sentimientos:

```
Sentiment
Positive    0.642183
Negative    0.222801
Neutral     0.135016
Name: proportion, dtype: float64
```

Conclusión Estratégica – Análisis de Sentimiento

El análisis de polaridad muestra que tanto aplicaciones gratuitas como de paga tienden a concentrar sentimientos positivos.

Sin embargo, la variabilidad en aplicaciones gratuitas es mayor, lo que sugiere:

- Mayor volumen de usuarios.
- Mayor diversidad en experiencias.
- Mayor exposición a críticas.

Las aplicaciones de paga muestran una distribución más estable, lo que podría indicar:

- Público más segmentado.
- Expectativas más claras.
- Mayor alineación entre valor percibido y precio.

Desde una perspectiva de negocio, el análisis de sentimiento complementa el rating tradicional, permitiendo evaluar calidad percibida más allá del promedio numérico.

9. Síntesis Ejecutiva

El análisis exploratorio evidencia que:

- La competencia es alta en categorías masivas como Game y Family.
- El mercado establece un estándar competitivo mínimo de rating > 4.0.
- El precio no penaliza necesariamente el rating si existe valor percibido.
- El sentimiento del usuario complementa el rating promedio como indicador de percepción real.

En términos estratégicos, el éxito de una aplicación depende menos de variables técnicas como tamaño y más de experiencia, segmentación y propuesta de valor clara.

Limitaciones del Estudio

- El dataset representa una fotografía estática del mercado.
- No se incluyen variables temporales.
- La correlación no implica causalidad.
- El análisis de sentimiento depende de procesamiento previo del texto.

Futuros análisis podrían incorporar modelos predictivos o segmentación avanzada.

10. Conclusión Final del Análisis

A lo largo de este análisis exploratorio del mercado de aplicaciones en Google Play Store se identificaron patrones relevantes en términos de categorías, calificaciones, tamaño, precio y percepción del usuario.

Resultados Cuantitativos Clave

El análisis se realizó sobre un total de 8,196 aplicaciones activas después del proceso de limpieza de datos.

El rating promedio global del mercado es 4.173, lo que confirma que el ecosistema presenta una tendencia positiva en la evaluación de los usuarios.

Al segmentar por modelo de negocio:

- Aplicaciones gratuitas: rating promedio de 4.166
- Aplicaciones de paga: rating promedio de 4.260

Esto indica que las aplicaciones de paga mantienen ligeramente mejores evaluaciones, posiblemente asociadas a mayor calidad percibida o segmentación de nicho.

El 92.63% del mercado está compuesto por aplicaciones gratuitas, lo que confirma que el modelo freemium domina claramente el ecosistema.

En términos de crecimiento y adopción, la correlación entre Rating y Log_Installs es de 0.085, lo que indica una relación positiva pero débil. Esto sugiere que una alta calificación no garantiza necesariamente un mayor volumen de descargas.

El análisis de sentimiento muestra la siguiente distribución:

- 64.22% reseñas positivas
- 22.28% reseñas negativas
- 13.50% reseñas neutrales

La percepción general del mercado es predominantemente positiva, aunque existe un porcentaje relevante de experiencias negativas que podrían representar oportunidades de mejora.

Implicaciones Estratégicas

Los hallazgos sugieren que:

- El mercado está altamente segmentado, con fuerte concentración en categorías masivas como Family y Game.
- Mantener un rating superior a 4.0 es prácticamente un requisito competitivo.
- El modelo gratuito domina el mercado, pero las apps de paga pueden competir con éxito si ofrecen alto valor percibido.

- La experiencia del usuario y la gestión de reputación digital son factores críticos para la sostenibilidad.

Este análisis no solo permite comprender el comportamiento actual del mercado, sino también diseñar estrategias fundamentadas en datos para el desarrollo de productos digitales competitivos.

11. Recomendaciones Ejecutivas

Desde una perspectiva de toma de decisiones estratégicas, se sugieren las siguientes líneas de acción:

Estrategia de Monetización

Dado que el 92.63% del mercado es gratuito, ingresar con un modelo Paid requiere diferenciación clara. Modelo freemium con monetización progresiva podría maximizar penetración inicial.

Optimización de Experiencia de Usuario

El rating promedio competitivo (4.173) establece un umbral mínimo. Se recomienda:

Testing continuo

Optimización de rendimiento

Respuesta activa a reseñas negativas

Posicionamiento por Nicho

Las apps de paga muestran mejor rating promedio. Esto sugiere oportunidades en segmentos especializados (productividad, finanzas, profesional).

Gestión de Reputación

Con 22.28% de sentimiento negativo, existe riesgo reputacional. Implementar análisis continuo de reviews puede anticipar crisis de percepción.

Decisiones Basadas en Datos

La baja correlación entre instalaciones y rating indica que crecimiento en volumen no garantiza calidad percibida. Las métricas de satisfacción deben medirse independientemente del crecimiento.