

Proyecto de Machine Learning

Conclusiones Ejecutivas – Aprendizaje Supervisado

1. Objetivo del Proyecto

El proyecto integró dos aplicaciones prácticas de Aprendizaje Supervisado: clasificación predictiva de riesgo cardiovascular y reconocimiento de dígitos manuscritos mediante el dataset MNIST.

Ambos casos permitieron implementar el flujo completo de un pipeline de Machine Learning, desde el análisis exploratorio hasta la validación sobre datos nuevos.

2. Clasificación Predictiva – Riesgo Cardiovascular

Análisis Exploratorio

Se identificaron relaciones relevantes entre variables clínicas y la probabilidad de riesgo cardiovascular. La matriz de correlación mostró asociaciones significativas en variables como:

- Tipo de dolor torácico
- Frecuencia cardíaca máxima alcanzada
- Número de vasos principales afectados
- Resultados de pruebas de esfuerzo

Estos hallazgos validan la coherencia estructural del dataset y su utilidad para modelado predictivo.

Modelo Implementado

Se utilizó el algoritmo k-Nearest Neighbors (k-NN), modelo no paramétrico basado en distancias. El escalamiento previo de variables fue fundamental para evitar sesgos derivados de magnitudes heterogéneas.

Evaluación

- Accuracy competitivo
- Matriz de confusión balanceada
- Desempeño sólido en precisión y recall

El modelo demuestra capacidad adecuada para discriminar entre pacientes con y sin riesgo cardiovascular.

3. Reconocimiento de Dígitos – MNIST

Naturaleza del Problema

El dataset MNIST representa un problema de clasificación multiclase con 784 variables derivadas de imágenes de 28x28 píxeles.

Reducción de Dimensionalidad

Se aplicó Análisis de Componentes Principales (PCA), conservando el 95% de la varianza explicada.

- Reducción significativa de variables
- Optimización del tiempo de entrenamiento
- Menor complejidad computacional
- Mantenimiento del poder predictivo

Modelos Comparados

- k-Nearest Neighbors
- Regresión Logística

Ambos modelos mostraron alto desempeño predictivo, con diferencias mínimas en accuracy.

Validación con Imagen Externa

La prueba con una imagen dibujada manualmente confirmó la correcta implementación del pipeline completo:

- Conversión a escala de grises
- Redimensionamiento
- Escalamiento consistente
- Transformación con PCA
- Predicción final

La correcta clasificación valida la capacidad de generalización del modelo.

4. Principios Metodológicos Aplicados

- Separación entrenamiento/prueba
- Preprocesamiento y escalamiento adecuado
- Reducción de dimensionalidad estratégica
- Evaluación con métricas objetivas
- Validación en datos nuevos

La comparación entre modelos demuestra que la elección del algoritmo debe considerar interpretabilidad, complejidad computacional y escalabilidad, además del accuracy.

5. Conclusión General

Los resultados demuestran que los modelos de Aprendizaje Supervisado pueden aplicarse eficazmente en distintos dominios, desde salud hasta visión computacional, siempre que se construyan pipelines estructurados, reproducibles y correctamente evaluados.

El proyecto evidencia dominio en clasificación binaria y multiclase, reducción de dimensionalidad, comparación de modelos y validación externa, cumpliendo con los objetivos planteados con rigor metodológico.

Proyecto M26 – Machine Learning
Clasificación y Reconocimiento de Patrones