

Análisis de Distribuciones y Pruebas de Hipótesis

Aplicación de estadística inferencial en comportamiento de clientes

Autor: RobertScience Data Consulting

Proyecto: Práctica M32 – Estadística Inferencial

Herramienta: Python / Jupyter Notebook

Entorno: Visual Studio Code

Descripción del proyecto

El presente análisis tiene como objetivo aplicar conceptos fundamentales de **estadística inferencial** mediante el uso de distribuciones de probabilidad y pruebas de hipótesis.

Se desarrollan dos enfoques principales:

1. **Simulación de una distribución de Poisson**, con el fin de modelar eventos discretos en el tiempo.
2. **Prueba de hipótesis (ANOVA)** para evaluar la relación entre variables de comportamiento digital de clientes.

Este análisis permite transformar datos en evidencia estadística para la toma de decisiones en contextos reales de negocio.

Importación de librerías

Se importan las librerías necesarias para el análisis estadístico.

- **pandas y numpy** para manipulación de datos
- **matplotlib y seaborn** para visualización
- **scipy** para trabajar con distribuciones de probabilidad y pruebas de hipótesis

Estas herramientas permiten desarrollar un análisis completo desde la simulación hasta la validación estadística.


```
array([4, 1, 3, 3, 1, 2, 2, 3, 2, 2], dtype=int32)
```

Simulación de distribución de Poisson

Se genera una muestra de 1000 observaciones utilizando una distribución de Poisson con parámetro $\lambda = 2.5$.

Esta distribución es adecuada para modelar la ocurrencia de eventos discretos en intervalos de tiempo, como el número de eventos que suceden en un año.

El parámetro λ representa el número promedio esperado de ocurrencias.



Visualización de la distribución

Se representa gráficamente la distribución simulada mediante un histograma.

La forma observada refleja una distribución discreta con mayor concentración en valores cercanos al promedio esperado.

Este comportamiento es característico de procesos donde los eventos ocurren de manera independiente.

	ID	Year_Birth	Education	Marital_Status	Income	Kidhome	Teenhome	Dt_Customer	Recen
0	5524	1957	Graduation	Single	58138.0	0	0	04-09-2012	!
1	2174	1954	Graduation	Single	46344.0	1	1	08-03-2014	3
2	4141	1965	Graduation	Together	71613.0	0	0	21-08-2013	2
3	6182	1984	Graduation	Together	26646.0	1	0	10-02-2014	2
4	5324	1981	PhD	Married	58293.0	1	0	19-01-2014	9

5 rows × 29 columns



Carga del conjunto de datos

Se carga el dataset de campañas de marketing desde un archivo local incluido en el proyecto.

Esto permite garantizar la reproducibilidad del análisis en cualquier entorno de ejecución.

El conjunto de datos contiene información sobre el comportamiento de clientes, incluyendo interacciones digitales y compras realizadas.

	NumWebPurchases	NumWebVisitsMonth
count	2240.000000	2240.000000
mean	4.084821	5.316518
std	2.778714	2.426645
min	0.000000	0.000000
25%	2.000000	3.000000
50%	4.000000	6.000000
75%	6.000000	7.000000
max	27.000000	20.000000

Análisis descriptivo

Se observa que el promedio de compras web es aproximadamente 4, mientras que el promedio de visitas mensuales es cercano a 5.

Esto sugiere un nivel moderado de interacción digital, lo que justifica analizar si existe relación entre ambas variables.

	Grupo_Visitas	NumWebPurchases
0	Alto	8
1	Bajo	1
2	Bajo	8
3	Alto	2
4	Bajo	5

Segmentación de clientes

Se agrupan los clientes en dos categorías:

- **Alto número de visitas:** más de 5 visitas mensuales
- **Bajo número de visitas:** 5 o menos visitas

Esta segmentación permite comparar el comportamiento de compra entre distintos niveles de interacción digital.

Normalidad grupo alto: ShapiroResult(statistic=np.float64(0.8814991660460341), pvalue=np.float64(5.759527597911519e-29))

Normalidad grupo bajo: ShapiroResult(statistic=np.float64(0.8642939742385977), pvalue=np.float64(1.9859610345181848e-29))

Homogeneidad de varianzas (Levene):

LeveneResult(statistic=np.float64(18.867914654916518), pvalue=np.float64(1.4634176350414265e-05))

F_onewayResult(statistic=np.float64(8.503662361325574), pvalue=np.float64(0.0035795823308853187))

Estadístico F: 8.50

Valor p: 0.0036

Prueba de hipótesis (ANOVA)

Se aplica una prueba ANOVA para evaluar si existen diferencias significativas en el número de compras entre los grupos definidos.

- **Hipótesis nula (H_0):** No hay diferencia en la media de compras entre los grupos
- **Hipótesis alternativa (H_1):** Al menos uno de los grupos presenta una media diferente

A partir del análisis realizado, se obtuvo un **valor p menor a 0.05**, lo cual indica evidencia estadística suficiente para rechazar la hipótesis nula.

Asimismo, el valor del estadístico F respalda que la variabilidad entre los grupos es mayor que la variabilidad dentro de los mismos.

Por lo tanto, se **rechaza la hipótesis nula (H_0)** y se concluye que existen diferencias estadísticamente significativas en el número de compras entre los grupos de clientes.

Este resultado indica que el nivel de visitas al sitio web está asociado con cambios en el comportamiento de compra, evidenciando que la interacción digital influye en la cantidad de compras realizadas.

Conclusión

El análisis permitió aplicar herramientas de estadística inferencial para modelar fenómenos y evaluar relaciones entre variables.

La simulación de la distribución de Poisson evidenció cómo es posible representar procesos aleatorios discretos en el tiempo, proporcionando una aproximación probabilística al comportamiento de eventos.

Por otro lado, la prueba ANOVA permitió analizar la relación entre la interacción digital de los clientes y su comportamiento de compra. Los resultados obtenidos sugieren que el nivel de visitas al sitio web está asociado con diferencias en el número de compras realizadas.

En conjunto, este enfoque demuestra el valor de la estadística como herramienta para transformar datos en información accionable, facilitando la toma de decisiones basada en evidencia.