

# Análisis de Precios de Vivienda mediante Modelos de Regresión

## Evaluación estadística y modelado predictivo

**Autor:** RobertScience Data Consulting  
**Proyecto:** Práctica M33 – Estadística Avanzada & Regresión Lineal  
**Herramienta:** Python / Jupyter Notebook  
**Entorno:** Visual Studio Code

## Descripción del proyecto

El presente análisis tiene como objetivo aplicar técnicas de **estadística avanzada y modelado predictivo** para comprender los factores que influyen en el precio de venta de viviendas.

A partir del dataset *House Pricing*, se desarrollan las siguientes etapas:

- Análisis exploratorio de variables numéricas
- Evaluación de la distribución de los datos mediante pruebas de normalidad
- Cálculo de métricas estadísticas clave
- Análisis de correlación entre variables
- Construcción de un modelo de regresión lineal (OLS)
- Evaluación de multicolinealidad mediante VIF
- Optimización del modelo final

Este análisis permite identificar variables relevantes en la determinación del precio de una propiedad, aportando información clave para la toma de decisiones en contextos inmobiliarios y financieros.

© 2026 RobertScience Data Consulting — Data Science & Advanced Analytics  
<https://robertscience.online/>

|          | <b>Id</b> | <b>MSSubClass</b> | <b>MSZoning</b> | <b>LotFrontage</b> | <b>LotArea</b> | <b>Street</b> | <b>Alley</b> | <b>LotShape</b> | <b>LandContour</b> | <b>Utilities</b> |
|----------|-----------|-------------------|-----------------|--------------------|----------------|---------------|--------------|-----------------|--------------------|------------------|
| <b>0</b> | 1         | 60                | RL              | 65.0               | 8450           | Pave          | NaN          | Reg             | Lvl                | AllPu            |
| <b>1</b> | 2         | 20                | RL              | 80.0               | 9600           | Pave          | NaN          | Reg             | Lvl                | AllPu            |
| <b>2</b> | 3         | 60                | RL              | 68.0               | 11250          | Pave          | NaN          | IR1             | Lvl                | AllPu            |
| <b>3</b> | 4         | 70                | RL              | 60.0               | 9550           | Pave          | NaN          | IR1             | Lvl                | AllPu            |
| <b>4</b> | 5         | 60                | RL              | 84.0               | 14260          | Pave          | NaN          | IR1             | Lvl                | AllPu            |

5 rows × 81 columns



# Comprensión del dataset

El conjunto de datos contiene información detallada sobre propiedades residenciales, incluyendo características estructurales, ubicación, calidad de construcción y variables relacionadas con el proceso de venta.

La variable objetivo del análisis es:

- **SalePrice:** Precio de venta de la propiedad

Algunas variables clave incluyen:

- **GrLivArea:** Área habitable
- **2ndFlrSF:** Área del segundo piso
- **TotalBsmntSF:** Área del sótano
- **OverallQual:** Calidad general de la vivienda

Estas variables serán fundamentales para el análisis estadístico y la construcción del modelo predictivo.

<class 'pandas.DataFrame'>

RangeIndex: 1460 entries, 0 to 1459

Data columns (total 81 columns):

| #  | Column       | Non-Null Count | Dtype   |
|----|--------------|----------------|---------|
| 0  | Id           | 1460 non-null  | int64   |
| 1  | MSSubClass   | 1460 non-null  | int64   |
| 2  | MSZoning     | 1460 non-null  | str     |
| 3  | LotFrontage  | 1201 non-null  | float64 |
| 4  | LotArea      | 1460 non-null  | int64   |
| 5  | Street       | 1460 non-null  | str     |
| 6  | Alley        | 91 non-null    | str     |
| 7  | LotShape     | 1460 non-null  | str     |
| 8  | LandContour  | 1460 non-null  | str     |
| 9  | Utilities    | 1460 non-null  | str     |
| 10 | LotConfig    | 1460 non-null  | str     |
| 11 | LandSlope    | 1460 non-null  | str     |
| 12 | Neighborhood | 1460 non-null  | str     |
| 13 | Condition1   | 1460 non-null  | str     |
| 14 | Condition2   | 1460 non-null  | str     |
| 15 | BldgType     | 1460 non-null  | str     |
| 16 | HouseStyle   | 1460 non-null  | str     |
| 17 | OverallQual  | 1460 non-null  | int64   |
| 18 | OverallCond  | 1460 non-null  | int64   |
| 19 | YearBuilt    | 1460 non-null  | int64   |
| 20 | YearRemodAdd | 1460 non-null  | int64   |
| 21 | RoofStyle    | 1460 non-null  | str     |
| 22 | RoofMatl     | 1460 non-null  | str     |
| 23 | Exterior1st  | 1460 non-null  | str     |
| 24 | Exterior2nd  | 1460 non-null  | str     |
| 25 | MasVnrType   | 588 non-null   | str     |
| 26 | MasVnrArea   | 1452 non-null  | float64 |
| 27 | ExterQual    | 1460 non-null  | str     |
| 28 | ExterCond    | 1460 non-null  | str     |
| 29 | Foundation   | 1460 non-null  | str     |
| 30 | BsmtQual     | 1423 non-null  | str     |
| 31 | BsmtCond     | 1423 non-null  | str     |
| 32 | BsmtExposure | 1422 non-null  | str     |
| 33 | BsmtFinType1 | 1423 non-null  | str     |
| 34 | BsmtFinSF1   | 1460 non-null  | int64   |
| 35 | BsmtFinType2 | 1422 non-null  | str     |
| 36 | BsmtFinSF2   | 1460 non-null  | int64   |
| 37 | BsmtUnfSF    | 1460 non-null  | int64   |
| 38 | TotalBsmtSF  | 1460 non-null  | int64   |
| 39 | Heating      | 1460 non-null  | str     |
| 40 | HeatingQC    | 1460 non-null  | str     |
| 41 | CentralAir   | 1460 non-null  | str     |
| 42 | Electrical   | 1459 non-null  | str     |
| 43 | 1stFlrSF     | 1460 non-null  | int64   |
| 44 | 2ndFlrSF     | 1460 non-null  | int64   |
| 45 | LowQualFinSF | 1460 non-null  | int64   |
| 46 | GrLivArea    | 1460 non-null  | int64   |
| 47 | BsmtFullBath | 1460 non-null  | int64   |
| 48 | BsmtHalfBath | 1460 non-null  | int64   |
| 49 | FullBath     | 1460 non-null  | int64   |
| 50 | HalfBath     | 1460 non-null  | int64   |
| 51 | BedroomAbvGr | 1460 non-null  | int64   |
| 52 | KitchenAbvGr | 1460 non-null  | int64   |
| 53 | KitchenQual  | 1460 non-null  | str     |

```

54 TotRmsAbvGrd    1460 non-null    int64
55 Functional      1460 non-null    str
56 Fireplaces      1460 non-null    int64
57 FireplaceQu     770 non-null     str
58 GarageType      1379 non-null    str
59 GarageYrBlt     1379 non-null    float64
60 GarageFinish    1379 non-null    str
61 GarageCars      1460 non-null    int64
62 GarageArea      1460 non-null    int64
63 GarageQual      1379 non-null    str
64 GarageCond      1379 non-null    str
65 PavedDrive      1460 non-null    str
66 WoodDeckSF      1460 non-null    int64
67 OpenPorchSF     1460 non-null    int64
68 EnclosedPorch   1460 non-null    int64
69 3SsnPorch       1460 non-null    int64
70 ScreenPorch     1460 non-null    int64
71 PoolArea        1460 non-null    int64
72 PoolQC          7 non-null       str
73 Fence           281 non-null     str
74 MiscFeature     54 non-null      str
75 MiscVal         1460 non-null    int64
76 MoSold          1460 non-null    int64
77 YrSold          1460 non-null    int64
78 SaleType        1460 non-null    str
79 SaleCondition   1460 non-null    str
80 SalePrice       1460 non-null    int64
dtypes: float64(3), int64(35), str(43)
memory usage: 924.0 KB

```

```

PoolQC          1453
MiscFeature     1406
Alley           1369
Fence           1179
MasVnrType      872
FireplaceQu     690
LotFrontage     259
GarageYrBlt     81
GarageCond      81
GarageType      81
dtype: int64

```

## Análisis de valores faltantes

Se realizó una verificación de valores nulos en el dataset con el objetivo de identificar posibles problemas de calidad de datos.

Las variables con valores faltantes pueden afectar el desempeño del modelo, por lo que es importante considerar su tratamiento en etapas posteriores.

En este análisis, las variables seleccionadas para el modelo no presentan valores nulos críticos, por lo que no fue necesario aplicar imputaciones.

|       | Id          | MSSubClass  | LotFrontage | LotArea       | OverallQual | OverallCond | YearBui     |
|-------|-------------|-------------|-------------|---------------|-------------|-------------|-------------|
| count | 1460.000000 | 1460.000000 | 1201.000000 | 1460.000000   | 1460.000000 | 1460.000000 | 1460.000000 |
| mean  | 730.500000  | 56.897260   | 70.049958   | 10516.828082  | 6.099315    | 5.575342    | 1971.267800 |
| std   | 421.610009  | 42.300571   | 24.284752   | 9981.264932   | 1.382997    | 1.112799    | 30.202900   |
| min   | 1.000000    | 20.000000   | 21.000000   | 1300.000000   | 1.000000    | 1.000000    | 1872.000000 |
| 25%   | 365.750000  | 20.000000   | 59.000000   | 7553.500000   | 5.000000    | 5.000000    | 1954.000000 |
| 50%   | 730.500000  | 50.000000   | 69.000000   | 9478.500000   | 6.000000    | 5.000000    | 1973.000000 |
| 75%   | 1095.250000 | 70.000000   | 80.000000   | 11601.500000  | 7.000000    | 6.000000    | 2000.000000 |
| max   | 1460.000000 | 190.000000  | 313.000000  | 215245.000000 | 10.000000   | 9.000000    | 2010.000000 |

8 rows × 38 columns



## Exploración inicial de los datos

Se realizó una revisión general del dataset con el objetivo de identificar:

- Tipos de variables
- Presencia de valores nulos
- Distribución general de los datos

Las estadísticas descriptivas permiten observar la media, desviación estándar, valores mínimos y máximos, lo cual proporciona una primera aproximación al comportamiento de las variables.

Esta etapa es fundamental para detectar posibles anomalías, outliers o necesidades de transformación antes de aplicar modelos estadísticos.

|   | SalePrice | GrLivArea | 2ndFlrSF |
|---|-----------|-----------|----------|
| 0 | 208500    | 1710      | 854      |
| 1 | 181500    | 1262      | 0        |
| 2 | 223500    | 1786      | 866      |
| 3 | 140000    | 1717      | 756      |
| 4 | 250000    | 2198      | 1053     |



## Selección de variables para análisis


Se seleccionaron variables numéricas relevantes para evaluar su comportamiento estadístico y su relación con el precio de venta:

- **SalePrice:** Variable objetivo del modelo
- **GrLivArea:** Área habitable

- **2ndFlrSF**: Área del segundo piso

Estas variables permiten analizar tanto la distribución del precio como su relación con características físicas de la propiedad.





## Análisis de distribución

A partir de los histogramas generados, se observa que:

- **SalePrice** presenta una distribución asimétrica positiva, con una cola hacia la derecha, lo que indica la presencia de propiedades con precios significativamente más altos que el promedio.
- **GrLivArea** muestra un comportamiento similar, con valores concentrados en rangos medios y algunos outliers hacia valores altos.
- **2ndFlrSF** presenta una alta concentración de valores en cero, lo que sugiere que muchas propiedades no cuentan con segundo piso.

En general, las variables analizadas no siguen una distribución normal, lo cual es relevante para la selección y validación de modelos estadísticos.

|                  | count  | mean          | std          | min     | 25%      | 50%      | 75%       | max      |
|------------------|--------|---------------|--------------|---------|----------|----------|-----------|----------|
| <b>SalePrice</b> | 1460.0 | 180921.195890 | 79442.502883 | 34900.0 | 129975.0 | 163000.0 | 214000.00 | 755000.0 |
| <b>GrLivArea</b> | 1460.0 | 1515.463699   | 525.480383   | 334.0   | 1129.5   | 1464.0   | 1776.75   | 5642.0   |
| <b>2ndFlrSF</b>  | 1460.0 | 346.992466    | 436.528436   | 0.0     | 0.0      | 0.0      | 728.00    | 2065.0   |

## Análisis de métricas estadísticas

Las métricas descriptivas permiten identificar:

- Diferencias entre media y mediana, indicando posible asimetría
- Alta desviación estándar en variables como SalePrice, lo que refleja dispersión en los precios
- Amplio rango entre valores mínimos y máximos, sugiriendo la presencia de outliers

Estos elementos refuerzan la necesidad de evaluar formalmente la normalidad de los datos.

Variable: SalePrice  
Estadístico: 610.8359  
p-value: 0.0000  
Conclusión: No sigue distribución normal

Variable: GrLivArea  
Estadístico: 437.1203  
p-value: 0.0000  
Conclusión: No sigue distribución normal

Variable: 2ndFlrSF  
Estadístico: 163.1424  
p-value: 0.0000  
Conclusión: No sigue distribución normal

## Evaluación de normalidad

Los resultados de la prueba estadística indican que:

- Las variables presentan valores p inferiores a 0.05
- Esto implica el rechazo de la hipótesis nula de normalidad

En consecuencia, se concluye que las variables analizadas no siguen una distribución normal.


Este resultado es consistente con el análisis visual previo y tiene implicaciones importantes en la construcción del modelo, particularmente en la interpretación de los errores y posibles transformaciones de variables.

|             | Id        | MSSubClass | LotFrontage | LotArea   | OverallQual | OverallCond | YearBuilt |
|-------------|-----------|------------|-------------|-----------|-------------|-------------|-----------|
| Id          | 1.000000  | 0.011156   | -0.010601   | -0.033226 | -0.028365   | 0.012609    | -0.012713 |
| MSSubClass  | 0.011156  | 1.000000   | -0.386347   | -0.139781 | 0.032628    | -0.059316   | 0.027850  |
| LotFrontage | -0.010601 | -0.386347  | 1.000000    | 0.426095  | 0.251646    | -0.059213   | 0.123349  |
| LotArea     | -0.033226 | -0.139781  | 0.426095    | 1.000000  | 0.105806    | -0.005636   | 0.014228  |
| OverallQual | -0.028365 | 0.032628   | 0.251646    | 0.105806  | 1.000000    | -0.091932   | 0.572323  |

5 rows × 38 columns







```

SalePrice      1.000000
OverallQual    0.790982
GrLivArea      0.708624
GarageCars     0.640409
GarageArea     0.623431
TotalBsmtSF    0.613581
1stFlrSF      0.605852
FullBath       0.560664
TotRmsAbvGrd  0.533723
YearBuilt      0.522897
YearRemodAdd   0.507101
GarageYrBlt    0.486362
MasVnrArea     0.477493
Fireplaces     0.466929
BsmtFinSF1    0.386420
Name: SalePrice, dtype: float64

```

## Análisis de correlación

A partir de la matriz de correlación, se identificaron las variables con mayor relación con el precio de venta (**SalePrice**).

Las variables con mayor correlación positiva incluyen:

- **OverallQual**: Calidad general de la vivienda
- **GrLivArea**: Área habitable
- **GarageCars** y **GarageArea**: Capacidad y tamaño del garaje
- **TotalBsmtSF**: Área total del sótano

Estas variables presentan una relación directa con el precio, lo que indica que a mayor valor en estas características, mayor tiende a ser el precio de la propiedad.

Por otro lado, algunas variables presentan baja correlación, lo que sugiere menor relevancia en la explicación del precio.

Este análisis permite identificar las variables más importantes para la construcción del modelo de regresión.

|   | OverallQual | GrLivArea | GarageCars | GarageArea | TotalBsmtSF | 1stFlrSF | FullBath | TotRmsAbvGrd |
|---|-------------|-----------|------------|------------|-------------|----------|----------|--------------|
| 0 | 7           | 1710      | 2          | 548        | 856         | 856      | 2        | 8            |
| 1 | 6           | 1262      | 2          | 460        | 1262        | 1262     | 2        | 6            |
| 2 | 7           | 1786      | 2          | 608        | 920         | 920      | 2        | 6            |
| 3 | 7           | 1717      | 3          | 642        | 756         | 961      | 1        | 7            |
| 4 | 8           | 2198      | 3          | 836        | 1145        | 1145     | 2        | 9            |

## Selección de variables para el modelo

Se seleccionaron las variables con mayor correlación con la variable objetivo, excluyendo la propia variable de precio.

Este enfoque permite construir un modelo inicial basado en variables con alto poder explicativo, reduciendo ruido y mejorando la interpretabilidad del modelo.

Posteriormente, se evaluará la significancia estadística y la multicolinealidad para refinar el modelo final.

Train size: (1168, 10)  
Test size: (292, 10)

### OLS Regression Results

|                   |                  |                     |           |
|-------------------|------------------|---------------------|-----------|
| Dep. Variable:    | SalePrice        | R-squared:          | 0.765     |
| Model:            | OLS              | Adj. R-squared:     | 0.763     |
| Method:           | Least Squares    | F-statistic:        | 376.1     |
| Date:             | Thu, 26 Mar 2026 | Prob (F-statistic): | 0.00      |
| Time:             | 22:18:18         | Log-Likelihood:     | -13958.   |
| No. Observations: | 1168             | AIC:                | 2.794e+04 |
| Df Residuals:     | 1157             | BIC:                | 2.799e+04 |
| Df Model:         | 10               |                     |           |
| Covariance Type:  | nonrobust        |                     |           |

|              | coef       | std err  | t      | P> t  | [0.025    | 0.975]    |
|--------------|------------|----------|--------|-------|-----------|-----------|
| const        | -1.243e+06 | 1.42e+05 | -8.743 | 0.000 | -1.52e+06 | -9.64e+05 |
| OverallQual  | 1.965e+04  | 1303.098 | 15.076 | 0.000 | 1.71e+04  | 2.22e+04  |
| GrLivArea    | 48.0694    | 4.680    | 10.271 | 0.000 | 38.887    | 57.252    |
| GarageCars   | 1.131e+04  | 3405.199 | 3.322  | 0.001 | 4630.379  | 1.8e+04   |
| GarageArea   | 14.0722    | 11.638   | 1.209  | 0.227 | -8.761    | 36.905    |
| TotalBsmntSF | 15.0602    | 4.862    | 3.098  | 0.002 | 5.521     | 24.600    |
| 1stFlrSF     | 14.4064    | 5.555    | 2.594  | 0.010 | 3.508     | 25.305    |
| FullBath     | -7199.9913 | 2992.306 | -2.406 | 0.016 | -1.31e+04 | -1329.039 |
| TotRmsAbvGrd | 453.9639   | 1237.685 | 0.367  | 0.714 | -1974.394 | 2882.322  |
| YearBuilt    | 281.1141   | 55.087   | 5.103  | 0.000 | 173.033   | 389.195   |
| YearRemodAdd | 314.9759   | 70.059   | 4.496  | 0.000 | 177.519   | 452.433   |

|                |         |                   |           |
|----------------|---------|-------------------|-----------|
| Omnibus:       | 426.260 | Durbin-Watson:    | 2.035     |
| Prob(Omnibus): | 0.000   | Jarque-Bera (JB): | 40561.495 |
| Skew:          | -0.701  | Prob(JB):         | 0.00      |
| Kurtosis:      | 31.836  | Cond. No.         | 4.67e+05  |

#### Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

[2] The condition number is large, 4.67e+05. This might indicate that there are strong multicollinearity or other numerical problems.

## Resultados del modelo de regresión

El modelo de regresión lineal permite evaluar la relación entre las variables independientes y el precio de venta.

A partir del resumen del modelo se observa:

- Variables con valores p inferiores a 0.05 son estadísticamente significativas
- Algunas variables pueden no ser relevantes y deberán ser evaluadas para su posible eliminación
- El valor de  $R^2$  indica el nivel de explicación del modelo sobre la variabilidad del precio

Este análisis permite identificar qué variables aportan valor real al modelo predictivo.

|    | Variable     | VIF          |
|----|--------------|--------------|
| 0  | const        | 16661.046876 |
| 1  | OverallQual  | 2.616670     |
| 2  | GrLivArea    | 4.963140     |
| 3  | GarageCars   | 5.233621     |
| 4  | GarageArea   | 4.972156     |
| 5  | TotalBsmtSF  | 3.782160     |
| 6  | 1stFlrSF     | 3.800951     |
| 7  | FullBath     | 2.206541     |
| 8  | TotRmsAbvGrd | 3.310982     |
| 9  | YearBuilt    | 2.352567     |
| 10 | YearRemodAdd | 1.738429     |

## Evaluación de multicolinealidad

El Factor de Inflación de Varianza (VIF) permite identificar si existe multicolinealidad entre las variables independientes.

Criterios de interpretación:

- $VIF \approx 1 \rightarrow$  Sin correlación
- VIF entre 1 y 5  $\rightarrow$  Correlación moderada
- $VIF > 10 \rightarrow$  Alta multicolinealidad (problema crítico)

La presencia de multicolinealidad puede afectar la estabilidad del modelo y la interpretación de los coeficientes, por lo que es necesario eliminar o ajustar variables redundantes.

Se observó multicolinealidad principalmente entre variables relacionadas con dimensiones físicas de la propiedad, como el tamaño del garaje, por lo que se optó por conservar la variable con mayor capacidad explicativa dentro del modelo.

### OLS Regression Results

|                   |                  |                     |           |       |           |           |
|-------------------|------------------|---------------------|-----------|-------|-----------|-----------|
| Dep. Variable:    | SalePrice        | R-squared:          | 0.764     |       |           |           |
| Model:            | OLS              | Adj. R-squared:     | 0.763     |       |           |           |
| Method:           | Least Squares    | F-statistic:        | 417.6     |       |           |           |
| Date:             | Thu, 26 Mar 2026 | Prob (F-statistic): | 0.00      |       |           |           |
| Time:             | 22:18:19         | Log-Likelihood:     | -13958.   |       |           |           |
| No. Observations: | 1168             | AIC:                | 2.794e+04 |       |           |           |
| Df Residuals:     | 1158             | BIC:                | 2.799e+04 |       |           |           |
| Df Model:         | 9                |                     |           |       |           |           |
| Covariance Type:  | nonrobust        |                     |           |       |           |           |
| =====             |                  |                     |           |       |           |           |
|                   | coef             | std err             | t         | P> t  | [0.025    | 0.975]    |
| -----             |                  |                     |           |       |           |           |
| const             | -1.243e+06       | 1.42e+05            | -8.745    | 0.000 | -1.52e+06 | -9.64e+05 |
| OverallQual       | 1.961e+04        | 1302.980            | 15.048    | 0.000 | 1.71e+04  | 2.22e+04  |
| GrLivArea         | 48.8679          | 4.634               | 10.545    | 0.000 | 39.775    | 57.960    |
| GarageCars        | 1.462e+04        | 2026.675            | 7.214     | 0.000 | 1.06e+04  | 1.86e+04  |
| TotalBsmntSF      | 15.5384          | 4.847               | 3.206     | 0.001 | 6.029     | 25.048    |
| 1stFlrSF          | 14.7639          | 5.548               | 2.661     | 0.008 | 3.879     | 25.649    |
| FullBath          | -7525.8840       | 2980.739            | -2.525    | 0.012 | -1.34e+04 | -1677.631 |
| TotRmsAbvGrd      | 323.2540         | 1233.202            | 0.262     | 0.793 | -2096.305 | 2742.813  |
| YearBuilt         | 282.5902         | 55.084              | 5.130     | 0.000 | 174.514   | 390.666   |
| YearRemodAdd      | 313.8918         | 70.067              | 4.480     | 0.000 | 176.419   | 451.365   |
| =====             |                  |                     |           |       |           |           |
| Omnibus:          | 410.956          | Durbin-Watson:      | 2.041     |       |           |           |
| Prob(Omnibus):    | 0.000            | Jarque-Bera (JB):   | 37676.507 |       |           |           |
| Skew:             | -0.643           | Prob(JB):           | 0.00      |       |           |           |
| Kurtosis:         | 30.794           | Cond. No.           | 4.62e+05  |       |           |           |
| =====             |                  |                     |           |       |           |           |

#### Notes:

- [1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
- [2] The condition number is large, 4.62e+05. This might indicate that there are strong multicollinearity or other numerical problems.

## Importancia de variables

Se analizan los coeficientes del modelo como una aproximación al impacto relativo de cada variable sobre el precio.

Variables con mayor coeficiente absoluto tienen mayor influencia en la predicción del modelo.

|   | Variable     | Coefficiente  |
|---|--------------|---------------|
| 1 | OverallQual  | 1.960764e+04  |
| 3 | GarageCars   | 1.462070e+04  |
| 7 | TotRmsAbvGrd | 3.232540e+02  |
| 9 | YearRemodAdd | 3.138918e+02  |
| 8 | YearBuilt    | 2.825902e+02  |
| 2 | GrLivArea    | 4.886786e+01  |
| 4 | TotalBsmtSF  | 1.553842e+01  |
| 5 | 1stFlrSF     | 1.476389e+01  |
| 6 | FullBath     | -7.525884e+03 |
| 0 | const        | -1.243312e+06 |

## Interpretación del modelo

A partir del modelo refinado, se observa que:

- Las variables con coeficientes positivos incrementan el precio de la vivienda
- Variables con mayor magnitud en los coeficientes tienen mayor impacto relativo
- Los valores p ( $< 0.05$ ) confirman la significancia estadística de las variables clave

Desde una perspectiva de negocio:

- **OverallQual** suele ser el principal driver del precio
- **GrLivArea** impacta directamente como indicador de tamaño habitable
- Variables estructurales aportan valor incremental al modelo

Esto permite interpretar el modelo no solo como predictor, sino como herramienta de análisis estratégico.

## Implicaciones de negocio

Desde una perspectiva estratégica:

- Incrementos en **OverallQual** generan impactos significativos en el valor de mercado
- El tamaño habitable (**GrLivArea**) es un driver clave en pricing
- Variables estructurales tienen efecto acumulativo sobre el precio

Esto sugiere que estrategias de inversión en calidad y ampliación de espacios tienen retorno directo en la valorización inmobiliaria.

Asimismo, el modelo puede ser utilizado para:

- Evaluación automática de propiedades (AVM)
- Detección de propiedades subvaluadas

- Soporte en decisiones de inversión inmobiliaria

## Refinamiento del modelo

Con base en el análisis de multicolinealidad, se eliminaron variables que presentaban alta redundancia.

Esto permite:

- Mejorar la estabilidad del modelo
- Evitar distorsión en los coeficientes
- Incrementar la interpretabilidad

El modelo refinado conserva únicamente variables con mayor aporte estadístico y menor dependencia entre sí.

RMSE (test): 39513.20

$R^2$  (test): 0.7965

MAE: 24949.94

Adicionalmente, se calculó el Error Absoluto Medio (MAE), el cual permite interpretar el error promedio en unidades reales del precio.

Esta métrica complementa el RMSE, proporcionando una visión más robusta del desempeño del modelo.

## Evaluación del modelo

El desempeño del modelo se evaluó mediante las siguientes métricas:

- **RMSE (Root Mean Squared Error):** mide el error promedio en las predicciones
- **$R^2$  (Coeficiente de determinación):** indica el porcentaje de variabilidad explicada por el modelo

Un valor alto de  $R^2$  sugiere que el modelo tiene un buen nivel explicativo, mientras que un RMSE bajo indica precisión en las predicciones.

En conjunto, estas métricas permiten concluir que el modelo presenta un desempeño adecuado para la estimación del precio de viviendas.

### OLS Regression Results

|                   |                  |                     |        |
|-------------------|------------------|---------------------|--------|
| Dep. Variable:    | SalePrice        | R-squared:          | 0.812  |
| Model:            | OLS              | Adj. R-squared:     | 0.811  |
| Method:           | Least Squares    | F-statistic:        | 555.6  |
| Date:             | Thu, 26 Mar 2026 | Prob (F-statistic): | 0.00   |
| Time:             | 22:18:20         | Log-Likelihood:     | 417.12 |
| No. Observations: | 1168             | AIC:                | -814.2 |
| Df Residuals:     | 1158             | BIC:                | -763.6 |
| Df Model:         | 9                |                     |        |
| Covariance Type:  | nonrobust        |                     |        |

|              | coef      | std err  | t      | P> t  | [0.025   | 0.975] |
|--------------|-----------|----------|--------|-------|----------|--------|
| const        | 2.6115    | 0.642    | 4.067  | 0.000 | 1.352    | 3.871  |
| OverallQual  | 0.0940    | 0.006    | 15.978 | 0.000 | 0.082    | 0.106  |
| GrLivArea    | 0.0002    | 2.09e-05 | 10.300 | 0.000 | 0.000    | 0.000  |
| GarageCars   | 0.0929    | 0.009    | 10.152 | 0.000 | 0.075    | 0.111  |
| TotalBsmntSF | 6.668e-05 | 2.19e-05 | 3.046  | 0.002 | 2.37e-05 | 0.000  |
| 1stFlrSF     | 6.328e-05 | 2.51e-05 | 2.525  | 0.012 | 1.41e-05 | 0.000  |
| FullBath     | -0.0282   | 0.013    | -2.097 | 0.036 | -0.055   | -0.002 |
| TotRmsAbvGrd | 0.0066    | 0.006    | 1.179  | 0.239 | -0.004   | 0.017  |
| YearBuilt    | 0.0019    | 0.000    | 7.758  | 0.000 | 0.001    | 0.002  |
| YearRemodAdd | 0.0022    | 0.000    | 7.005  | 0.000 | 0.002    | 0.003  |

|                |         |                   |           |
|----------------|---------|-------------------|-----------|
| Omnibus:       | 754.224 | Durbin-Watson:    | 1.990     |
| Prob(Omnibus): | 0.000   | Jarque-Bera (JB): | 26463.650 |
| Skew:          | -2.438  | Prob(JB):         | 0.00      |
| Kurtosis:      | 25.804  | Cond. No.         | 4.62e+05  |

#### Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

[2] The condition number is large, 4.62e+05. This might indicate that there are strong multicollinearity or other numerical problems.

RMSE LOG (test): 31698.06

R<sup>2</sup> LOG (test): 0.8690

“La transformación log permite interpretar coeficientes como cambios porcentuales aproximados.”

## Transformación logarítmica

Dado que la variable **SalePrice** presenta una distribución asimétrica, se aplicó una transformación logarítmica con el objetivo de:


- Reducir la asimetría
- Estabilizar la varianza
- Mejorar el ajuste del modelo

Este tipo de transformación es común en modelos de regresión cuando se trabaja con variables económicas o de precios.


El modelo transformado permite una mejor interpretación en términos relativos (cambios porcentuales).




Valores reales vs predicción



Distribución de residuales





La gráfica de residuales contra predicciones permite verificar la homocedasticidad del modelo.

La dispersión aleatoria alrededor de cero sugiere que no existen patrones sistemáticos en los errores, lo cual respalda la validez del modelo.

## Validación del modelo

El análisis gráfico permite observar:

- La relación entre valores reales y predichos muestra una tendencia positiva, lo que indica que el modelo captura adecuadamente el comportamiento del precio.
- La distribución de los residuales presenta una forma aproximadamente centrada, lo que sugiere que los errores no presentan sesgos graves.

En conjunto, estos resultados respaldan la validez del modelo desde una perspectiva estadística.

## Conclusión

El análisis permitió identificar los principales factores que influyen en el precio de venta de viviendas, destacando variables como la calidad general de la propiedad, el área habitable y características estructurales relevantes.

Se comprobó que las variables analizadas no siguen una distribución normal, lo cual fue considerado durante la interpretación de los resultados.

El modelo de regresión lineal construido mostró un buen nivel de ajuste en datos de prueba, lo que indica una adecuada capacidad de generalización.

Asimismo, el análisis de multicolinealidad permitió depurar el modelo, asegurando mayor estabilidad y confiabilidad en los resultados.

En términos generales, el modelo desarrollado proporciona una herramienta sólida para la estimación de precios, con aplicaciones directas en análisis inmobiliario, valuación de propiedades y toma de decisiones basada en datos.

El modelo puede ser utilizado como base para sistemas de valuación automatizada en el sector inmobiliario.

Como mejora futura, el modelo podría beneficiarse del uso de técnicas de regularización como Ridge o Lasso, con el objetivo de incrementar la estabilidad de los coeficientes y reducir posibles efectos de multicolinealidad residual.

El modelo fue validado en datos no vistos (test set), garantizando su capacidad de generalización y evitando sobreajuste.

## Valor estratégico del modelo

Más allá del desempeño estadístico, este modelo representa una base sólida para sistemas de valuación automatizada (AVM), permitiendo escalar procesos de análisis inmobiliario y reducir la dependencia de evaluaciones manuales.

Esto posiciona el análisis dentro de un contexto real de aplicación en la industria PropTech y analítica avanzada.